

Fusão por Filtro de Kalman Estendido de Detecção Visual e Odometria sob Observação Esparsa: um Estudo de Caso em Gêmeo Digital Multi-Robô

Anonymous Author(s)

Institution withheld for double-blind review

Resumo No gêmeo digital estudado aqui, sistemas multi-robô que combinam odometria com detecção visual externa recorriam a um fallback discreto: confiar na detecção quando disponível, na odometria caso contrário. Essa abordagem descarta a incerteza de cada estimativa e não oferece um comportamento bem definido durante lacunas de detecção. Para resolver isso, substituímos o fallback por um Filtro de Kalman Estendido (EKF) por robô, fundindo odometria e detecção visual baseada em YOLO a partir de uma câmera fixa suspensa, validado em duas etapas: primeiro consistência estatística em dados sintéticos (NEES/NIS), depois avaliação em dados reais gravados, num gêmeo digital ROS2/Gazebo com três robôs TurtleBot3.

O resultado depende de como o erro é medido. Nos instantes de correção, o filtro reduz o erro de posição em +23,7% em relação à odometria isolada sob deriva agressiva, o ganho que a literatura tipicamente reporta. Mas, medido continuamente, a cada leitura de odometria, o mesmo filtro é 12,7% *pior* que a odometria bruta, sob a cobertura visual esparsa (0–28%) que nossa câmera exibe na prática. Mostramos que essa reversão de sinal é a consequência esperada de operar abaixo de uma taxa crítica de observação, não uma falha de projeto, e a conectamos mecanicamente a um teto de covariância necessário para manter estável a associação por gating de Mahalanobis. Reportar as duas métricas, e não apenas o ganho pontual comumente citado, é necessário para caracterizar honestamente a fusão por EKF sob observação esparsa; discutimos também por que filtros alternativos (UKF, filtro de partículas, IMM) não resolvem essa limitação, já que ela decorre da taxa de observação, não da escolha do filtro.

Keywords: Filtro de Kalman Estendido · Observações Intermitentes · Localização Cooperativa · Fusão Sensorial Assíncrona · Localização Multi-Robô

1 Introdução

Câmeras fixas suspensas observando múltiplos robôs móveis são infraestrutura comum em automação de armazéns, coordenação de frotas em ambientes internos e monitoramento de ambientes inteligentes, onde instalar uma carga sensorial

dedicada em cada robô é custosa ou inviável. Sistemas multi-robô que combinam odometria embarcada com essa detecção visual externa enfrentam uma escolha recorrente: como combinar duas estimativas de posição ruidosas, que chegam em taxas diferentes e nem sempre estão disponíveis no mesmo instante. Uma solução comum e pragmática, usada no gêmeo digital estudado aqui antes de nossa contribuição, é um *fallback discreto*: confiar na detecção quando associada com confiança, na odometria caso contrário. Essa abordagem descarta informação: não há correção parcial a partir de detecções de baixa confiança, nem propagação de incerteza, nem comportamento bem definido durante trechos sem detecção.

A Filtragem de Kalman Estendida (EKF) é a resposta clássica a esse problema, oferecendo predição e correção probabilística com propagação explícita de incerteza. Suas propriedades de convergência, no entanto, são classicamente estabelecidas sob observação razoavelmente densa e regular [5], uma suposição que uma única câmera fixa suspensa, sujeita a campo de visão finito e auto-occlusão durante manobras, não satisfaz em geral. Este trabalho investiga se essa violação importa na prática.

Substituímos o fallback discreto por um EKF por robô, fundindo odometria e detecção visual baseada em YOLO, avaliado de ponta a ponta no mesmo gêmeo digital. Nossa contribuição é dupla. Primeiro, validado em duas etapas, NEES/NIS sintético e depois dados reais gravados, o filtro entrega um ganho de fusão real: +23,7% de redução do erro de posição nos instantes de correção, sob deriva agressiva. Segundo, o mesmo filtro, medido continuamente e não apenas nos instantes de correção, é 12,7% pior que a odometria bruta sob a cobertura visual esparsa (0–28%) que nossa câmera exibe na prática. Explicamos essa reversão mecanicamente, conectando-a à teoria já estabelecida sobre filtragem de Kalman sob observações intermitentes [6,7]. Argumentamos que reportar ambas as métricas é necessário para uma caracterização honesta, e discutimos por que filtros alternativos não resolvem a limitação subjacente.

2 Trabalhos Relacionados

Durrant-Whyte e Bailey [4] formalizam o modelo padrão de movimento/observação do EKF que nosso filtro segue diretamente (odometria conduz a predição, detecções YOLO conduzem a correção; notação adotada na Seção 3). Dissanayake et al. [5] provam a convergência de covariância do EKF-SLAM sob observação *densa* de marcos, uma suposição que nossa câmera com 0–28% de cobertura viola por construção (central à Seção 4). Sinopoli et al. [6] estabelecem que, sob chegada de observação de Bernoulli, a covariância diverge abaixo de uma taxa crítica; nosso Cenário 3 (0% de cobertura observada) é consistente com o caso limite $p \rightarrow 0$, de modo que a saturação observada é teoricamente esperada, não um sintoma de má configuração. Censi [7] observa que esse limiar crítico depende da métrica de resumo de covariância usada; reportamos $\text{trace}(P)$ como uma escolha de escopo, não uma alegação de independência de métrica.

Khosravi et al. [10] reportam localização cooperativa descentralizada para dois robôs (correções mútuas via LiDAR), com redução de RMSE de 34%/56%, comparável em ordem de grandeza ao nosso +23,7%. Ahmed e Frémont [11] fundem um detector YOLOv8-RGBDis customizado com um EKF por alvo para uma equipe multi-robô marítima ($\text{mAP}@0.5 = 0,995$, numericamente próximo do nosso). Nenhum dos dois reporta um regime de erro contínuo em que a fusão perde para a linha de base sem fusão: o achado diferenciador deste trabalho. Dobrynin e Garcia [12] compartilham nossa plataforma exata (três TurtleBot3, ROS2), mas resolvem localização relativa sem câmera, portanto não encontram cobertura visual esparsa (revisitado como trabalho complementar na Seção 5). Nossa contribuição é o relato conjunto do ganho no instante de correção e da degradação do erro contínuo, fundamentado em [6,7] para explicar por que esse trade-off é esperado, e não um bug de implementação. Também não avaliamos contra um benchmark multi-robô público como UTIAS MRCLAM [13] ou S3E [14]: ambos assumem uma carga sensorial transportada por cada robô, enquanto nossa configuração observa os robôs a partir de uma única câmera externa e estática, mais próxima de um sensor fixo de ambiente inteligente do que de SLAM cooperativo. Até onde sabemos, nenhum conjunto de dados público combina esses três elementos, o que motiva o conjunto de dados gravado e disponibilizado com este trabalho (Seção 3). Esta cobertura reflete busca direcionada, não uma revisão sistemática da literatura com protocolo registrado; uma revisão formal continua em aberto.

3 Método

Seguindo Durrant-Whyte e Bailey [4], cada robô é rastreado por um EKF independente com estado $x_k = [p_x, p_y, \theta]^\top$. O modelo de movimento integra o *delta* entre leituras consecutivas de odometria sobre o estado atual, não o valor absoluto, o que descartaria correções visuais anteriores. O modelo de observação mapeia o estado para a posição 2D reportada por um detector YOLO em uma câmera fixa suspensa (Seção 3).

Predição e teto de covariância. O ruído de processo é $Q = \text{diag}(0, 5, 0, 5, 0, 25)$, escalado por $\Delta t/0,1$ para a taxa real de odometria (≈ 29 Hz vs. os 0,1s assumidos na calibração sintética); calibrado empiricamente (uma varredura de 10^{-6} a 1,0 mostrou ganho monotonicamente crescente até a saturação em $Q \geq 0,5$). Um teto rígido $\text{clip}(P, -\infty, 0,05)$ (elemento a elemento) é aplicado após cada predição: sem ele, P crescia sem limite durante intervalos longos sem correção ($\text{trace}(P) \approx 85$ observado vs. $\approx 0,5$ esperado), quebrando a associação por gating de Mahalanobis ao alargar a região de aceitação de um robô o suficiente para reivindicar a detecção de um vizinho. Tanto Q quanto esse teto foram calibrados exclusivamente contra o ganho no instante de correção na Tabela 1; a degradação de erro contínuo reportada adiante é, portanto, uma consequência observada dessa escolha, não um trade-off conjuntamente otimizado. Essa é uma resposta de engenharia à divergência que Sinopoli et al. [6] caracterizam para sistemas lineares abaixo de uma taxa crítica de observação; o resultado análogo

para o EKF é apenas local, condicional a ruído e erro inicial pequenos o suficiente [2], de modo que tratamos essa conexão como motivação mecanicista, não como garantia formal para nosso filtro não linear. O teto troca otimalidade estrita por comportamento limitado e previsível sob observação esparsa.

Associação de dados e correção. Cada detecção é atribuída via vizinho mais próximo com gating de Mahalanobis: $d^2 = e^\top P_{xy}^{-1} e$ por par (robô, detecção), aceito apenas se $d^2 \leq 9,21$ (99% de confiança, χ^2 , 2 graus de liberdade). Isso herda uma limitação conhecida (Altendorfer e Wirkert [9]): uma covariância inflada alarga a região de aceitação e pode enviesar a associação em direção a trajetórias mais incertas, o mesmo modo de falha que motiva o teto de covariância acima. Uma vez atribuída, o ruído de medição R é derivado linearmente da confiança de detecção do YOLO $c \in [0, 1]$, $\sigma = R_{\min} + (1 - c)(R_{\max} - R_{\min})$, $R_{\min} = 0,02$, $R_{\max} = 0,20$ m.

Calibração de câmera. Os intrínsecos vêm de `cv2.calibrateCamera` (Zhang [8]). Uma primeira tentativa com os quatro intrínsecos livres alcançou baixo erro de reprojeção (0,162px), mas uma distância focal mal-condicionada (f_x 33% acima do valor teórico derivado do FOV): o caso degenerado que o método de Zhang sofre quando o plano do tabuleiro permanece fronto-paralelo ao sensor em todas as poses, inevitável com nossa câmera fixa voltada para baixo. Corrigimos isso fixando f_x, f_y, c_x, c_y em seus valores nominais geométricos e calibrando apenas a distorção da lente, o remédio padrão quando os intrínsecos nominais já são conhecidos; a calibração corrigida reproduz a projeção heurística já usada em produção com erro de até 0,001m, confirmando que ambas são geometricamente equivalentes.

Validação. Seguindo os testes de consistência padrão para filtros de Kalman [1], checamos primeiro NEES e NIS em simulação antes de confiar no filtro em dados reais: 30 sementes de Monte Carlo (2000 passos cada) fornecem NEES= 2,955 (esperado 3,0) e NIS= 1,982 (esperado 2,0), dentro de 1,5%/0,9% de erro relativo, bem calibrado apesar de os limites formais de χ^2 a 95% serem estreitos demais para passar nesse tamanho de amostra. O filtro calibrado é então executado contra odometria e detecções YOLO reais gravadas do gêmeo digital ao vivo, onde a cobertura de observação é esparsa e irregular por construção, não por escolha de projeto.

Configuração experimental. Avaliamos nosso EKF em um gêmeo digital ROS2/Gazebo: três unidades TurtleBot3 Waffle junto a uma câmera fixa suspensa em (0,0,3) m, 90° de inclinação para baixo, 60° de campo de visão horizontal, 640×480@10 Hz. Cada robô também publica odometria (≈ 29 Hz) e uma leitura de LiDAR 2D não utilizada (Seção 5). A detecção de robôs usa um modelo YOLO treinado em 375 quadros anotados da mesma câmera, mAP@0.5 = 0,995; a confiança é carregada no campo z de outra forma não utilizado da mensagem de detecção, para consumo direto pela etapa de correção do EKF.

A Fig. 1 mostra a saída real desse pipeline de detecção: os três robôs, vistos pela câmera fixa suspensa, com as caixas delimitadoras e a confiança do YOLO sobrepostas.




Figura 1. Vista aérea da câmera fixa sobre os três robôs TurtleBot3, com as caixas delimitadoras e a confiança de detecção do modelo YOLO sobrepostas em tempo real.

Três cenários de ~ 18 s foram gravados como bags ROS2/MCAP: (a) **Estacionário**: 152 detecções vs. 550 leituras de odometria/robô, $\approx 28\%$ de cobertura, a mais alta dos três; (b) **Movimento reto** ($v_x = 0,1$ m/s): 144 vs. 522 leituras, $\approx 11\%$ de cobertura; (c) **Curva/occlusão** ($v_x = 0,12$ m/s, $\omega_z = 0,4$ rad/s): 145 detecções registradas, mas **zero** associadas com sucesso ao **robot1** durante toda a gravação, produzindo o caso de cobertura 0% central para a Seção 4. A sincronização de timestamp foi verificada via `rosvbag2_py` (nenhuma lacuna > 500 ms), descartando dessincronização de relógio de sensor como fator de confusão.

Disponibilizamos um pacote de reprodutibilidade (arquivo de mundo, URDF, calibração, hiperparâmetros do EKF, SHA do commit de código) e documentamos uma dependência não óbvia: `ros-humble-rosvbag2-storage-mcap` não vem instalado por padrão no ROS2 Humble.

4 Resultados e Discussão

Reportamos duas métricas de erro distintas, deliberadamente mantidas separadas: *erro no instante de correção*, medido apenas quando uma detecção YOLO é associada e fundida com sucesso (a mais comumente reportada em trabalhos relacionados; Seção 2), e *erro contínuo*, medido a cada leitura de odometria independentemente de correção. Essas duas métricas discordam em sinal, e ambas são necessárias para caracterizar honestamente o comportamento do filtro sob observação esparsa.

Erro no instante de correção. A validação NEES/NIS sintética (Seção 3) confirma que o filtro está bem calibrado antes de qualquer avaliação com dados reais (Fig. 2, $\text{NEES} \rightarrow 3,0$, $\text{NIS} \rightarrow 2,0$).

A Tabela 1 reporta o erro de posição sob três regimes de deriva de odometria injetada, agregados nos três cenários gravados ($n = 1323$). Sob deriva agressiva, o regime em que a odometria bruta já acumulou erro substancial antes que uma correção visual se torne disponível, o EKF reduz o erro médio de posição em $+23,7\%$ em relação à odometria isolada (teste de postos sinalizados de Wilcoxon,




Figura 2. Consistência de NEES e NIS ao longo da validação sintética de Monte Carlo (30 sementes, 2000 passos cada). Ambas as estatísticas acompanham seus valores teóricos esperados, indicando um filtro bem calibrado.




Figura 3. Trajetória estimada sob deriva agressiva, Cenário 2 (movimento reto). O EKF (azul) acompanha a ground truth (preto) mais de perto que a odometria bruta com deriva (laranja, tracejado).

$p < 0,001$; as amostras dentro de um cenário são temporalmente autocorrelacionadas, de modo que esse n superestima o número de tentativas independentes, e o p -valor deve ser lido como otimista, limitação agravada pelo fato de cada cenário durar apenas ~ 18 s). Sob deriva leve, o ganho é negativo ($-5,3\%$): o erro de detecção visual ($\approx 3\text{--}6$ cm) ainda não é menor que o erro de odometria, já pequeno, de modo que a fusão não oferece benefício, comportamento esperado para um filtro corretamente calibrado, não uma falha.

Tabela 1. Erro de posição no instante de correção (m), agregado nos 3 cenários ($n = 1323$). Cada célula reporta EKF / apenas odometria; as colunas Δ dão a redução relativa do EKF.

Deriva	Média EKF/Odom	Média Δ	RMSE EKF/Odom	RMSE Δ
Nenhuma (odom=GT)	0,036 / 0,000	N/D	0,052 / 0,000	N/D
Leve	0,053 / 0,050	$-5,3\%$	0,068 / 0,066	$-2,1\%$
Agressiva	0,128 / 0,168	+23,7%	0,163 / 0,195	+16,7%

A Fig. 3 mostra isso qualitativamente: a odometria bruta visivelmente se afasta do caminho reto de ground truth, enquanto a estimativa do EKF o acompanha mais de perto.

Erro contínuo: o achado central. Quando o erro é medido a *cada* leitura de odometria, o resultado se inverte. A Tabela 2 reporta o erro em tempo contínuo sob deriva agressiva, usando as mesmas gravações. Agregado em todas as leituras ($n = 1607$), o EKF é $12,7\%$ *pior* que a odometria bruta pelo erro médio e $13,4\%$ pior pelo RMSE (teste de postos sinalizados de Wilcoxon, $p < 0,001$),

o sinal oposto ao resultado no instante de correção, com o RMSE confirmando a mesma reversão, não um artefato da métrica de erro médio.

Tabela 2. Erro de posição contínuo (m), a cada leitura de odometria, deriva agressiva. Cada célula reporta EKF / apenas odometria; a mudança de RMSE confirma a mesma reversão do erro médio.

Cenário	Cob.	Média EKF/Odom	Média Δ	RMSE EKF/Odom	RMSE Δ
Estacionário	27,6%	0,212 / 0,177	-19,3%	0,246 / 0,205	-19,8%
Reto	11,3%	0,212 / 0,178	-18,8%	0,245 / 0,206	-19,2%
Curva/ocl.	0,0%	0,178 / 0,178	-0,0%	0,205 / 0,205	-0,0%
Agregado	—	0,200 / 0,178	-12,7%	0,233 / 0,205	-13,4%

O erro acima segue a convenção de Erro de Trajetória Absoluto (ATE) de Sturm et al. [15]: erro de posição por amostra contra a ground truth, sem alinhamento rígido, apropriado aqui porque estimativa, odometria e ground truth já compartilham um referencial de mundo comum via a câmera fixa (diferentemente de SLAM, onde a trajetória tem um gauge livre). O ATE isoladamente não consegue distinguir se a degradação vem do erro acumulando ao longo do tempo ou de cada passo já derivando mais. Por isso também reportamos o Erro de Pose Relativo (RPE) [15]: o erro do delta de posição entre leituras consecutivas, isolando o desvio local do erro global acumulado que o ATE captura. Agregado nos cenários, o RPE é 4,2% pior pelo erro médio e 4,8% pior pelo RMSE, o mesmo sinal do ATE mas substancialmente menor, indicando que a reversão é impulsionada majoritariamente pelo erro acumulando ao longo do tempo sob correção esparsa, não pelo desvio passo a passo.

Duas observações explicam essa reversão. Primeiro, a degradação escala inversamente com a cobertura do YOLO: o Cenário 3 (0% de cobertura) mostra uma mudança de exatamente 0,0%, porque, com zero correções, a etapa de predição do EKF degenera para pura integração de delta de odometria, idêntica matematicamente à linha de base sem fusão. Os Cenários 1 e 2 (27,6% e 11,3% de cobertura) mostram degradação semelhante de $\sim 19\%$ apesar de níveis de cobertura diferentes, sugerindo que o efeito satura rapidamente assim que as correções ficam esparsas o bastante para o teto de covariância (Seção 3) entrar em ação.

Segundo, e explicando mecanicamente o primeiro, a Fig. 4 mostra o porquê: $\text{trace}(P)$ satura no teto de covariância quase imediatamente após qualquer intervalo sem correção, e só cai quando uma correção ocorre. No Cenário 3, o traço satura já no primeiro passo observado e nunca mais cai. Esse é precisamente o regime de divergência previsto por Sinopoli et al. [6] para taxas de chegada de observação abaixo de um limiar crítico: o teto de covariância impede crescimento sem limite (e as falhas de associação que causaria) ao limitar a *própria estimativa de incerteza* do filtro, não tornando sua estimativa de estado mais precisa durante o intervalo sem correção: o filtro permanece superconfiante em sua predição baseada apenas em odometria, em relação a quão incerta essa predição realmente é.

Discussão. A leitura natural da Tabela 2 é desfavorável: nosso EKF, avaliado continuamente, perde para a odometria que deveria melhorar. Argumen-




Figura 4. Saturação da covariância de posição ao longo do tempo (gráficos em degraus), nos três cenários, sob duas métricas (topo: $\text{trace}(P_{xy})$; base: $\lambda_{\max}(P_{xy})$, o maior autovalor), seguindo a observação de Censi [7] de que o limiar crítico de observação depende da métrica de erro escolhida. Traços verticais na base de cada painel marcam correções YOLO bem-sucedidas. Linhas tracejadas marcam o teto de cada métrica sob o mesmo clip elemento a elemento (Seção 3): $2 \times \text{COV_CAP} = 0,1$ para o traço e $\text{COV_CAP} = 0,05$ para o maior autovalor isoladamente. Ambas as métricas concordam qualitativamente: a cobertura diminui da esquerda para a direita (27,6% $\rightarrow$ 11,3% $\rightarrow$ 0%), e a covariância satura em seu teto por trechos correspondentemente mais longos, atingindo saturação permanente no caso de cobertura zero.

tamos que isso é esperado, não um projeto falho. A prova de convergência de Dissanayake et al. [5] assume observação densa; nossa câmera viola isso por construção (0–28% de cobertura), e Sinopoli et al. [6] preveem exatamente essa divergência de covariância sem um teto, e a superconfiança resultante com um teto presente. A mudança de 0,0% do Cenário 3 é uma confirmação limpa: com zero correções, a etapa de predição é comprovadamente idêntica à integração de delta de odometria. Seguimos Censi [7] ao reportar $\text{trace}(P)$ como uma escolha de escopo, não uma alegação de divergência independente de métrica.

Nenhuma alternativa padrão resolve o caso de cobertura zero: um filtro de partículas degenera para pura propagação de processo, sem verossimilhança para reponderar; um filtro IMM ainda exige alguma observação para ponderar modos concorrentes; e um UKF visa a não linearidade do modelo de observação, não a taxa de observação, distinção apoiada pelo fato de que uma divergência análoga em taxa crítica já foi demonstrada para o UKF sob observações intermitentes [3]. Tratamos a baixa cobertura como a causa raiz, consistente com a literatura de posicionamento de sensores: limites de estimação sob uma dada topologia de

sensor se mantêm independentemente do filtro usado. O teto de covariância é, portanto, uma aproximação de engenharia para manter uma estimativa de estado limitada e previsível durante lacunas de observação, trocando otimalidade por estabilidade de associação, e herda uma limitação de gating conhecida (Altendorfer e Wirkert [9]): uma covariância saturada alarga a região de aceitação precisamente quando a incerteza real é pior caracterizada por um valor fixo, embora não tenhamos observado associação cruzada incorreta entre robôs em nossos três cenários.

Testamos esse trade-off diretamente, em vez de apenas argumentá-lo. Um fator de esquecimento (Adaptive Fading Kalman Filter), a alternativa tecnicamente correta por preservar a estrutura semidefinida positiva de P , foi implementado e avaliado sob o mesmo protocolo. Sem teto, o ganho caiu de $+23,7\%/+16,7\%$ (clip) para $-18,5\%/-112,5\%$. Um teto mais generoso recuperou um ganho positivo de erro médio na configuração mais restritiva testada ($0,1$: $+9,1\%$ de média, mas $-38,8\%$ de RMSE, indicando outliers grandes ocasionais), degradando novamente conforme o teto se alarga ($0,2$: $-3,9\%$; $0,3$: $-19,3\%/-111,3\%$). Nenhuma configuração igualou o clip nas duas métricas simultaneamente, e as duas métricas discordaram em sinal na única configuração em que o erro médio melhorou. Esse comportamento não monotônico é, por si só, evidência contra o fator de esquecimento como substituto direto: seu comportamento prático depende sensivelmente de um hiperparâmetro adicional sem um padrão principiado, e um teto mais frouxo ainda permite que P cresça o suficiente para a associação com gating de Mahalanobis aceitar a detecção de um robô vizinho, o mesmo modo de falha que o clip existe para evitar. Reportamos isso como evidência empírica, não apenas justificativa teórica, para a escolha do clip.

5 Trabalhos Futuros e Conclusão

Trabalhos futuros. Direções concretas incluem: (a) **ruído de processo adaptativo**: escalar Q pelo tempo desde a última correção em vez de um teto fixo, mais principiado mas, como nosso teste do fator de esquecimento mostra, não uma melhora garantida sem ajuste adicional; (b) **LiDAR como terceira fonte de fusão**: cada robô já publica leituras 2D não utilizadas; correções mútuas via LiDAR (no espírito de Khosravi et al. [10]) poderiam mirar diretamente o regime de cobertura zero; (c) **incerteza de projeção formal**: propagar o Jacobiano completo de projeção para R ; (d) **localização relativa distribuída**: a filtragem distribuída sem câmera de Dobrynin e Garcia [12] na mesma plataforma poderia fornecer um segundo canal de correção durante lacunas de cobertura visual.

Conclusão. Substituímos um fallback discreto visual/odometria por um Filtro de Kalman Estendido validado em duas etapas, avaliado em dados reais gravados de três robôs TurtleBot3. O filtro entrega um ganho genuíno nos instantes de correção ($+23,7\%$), mas é mensuravelmente pior que a odometria bruta quando avaliado continuamente ($-12,7\%$) sob 0 – 28% de cobertura visual, incluindo um cenário de cobertura zero que colapsa, exatamente como esperado, para a linha de base sem fusão. Em vez de reportar apenas a métrica favorável,

caracterizamos ambas e fundamentamos a reversão na teoria estabelecida sobre filtragem de Kalman sob observação intermitente. A fusão por EKF continua sendo a ferramenta certa para este problema, mas sua correção sob observação esparsa precisa ser medida e reportada explicitamente, e a própria taxa de observação, não a escolha do filtro, é a restrição vinculante que trabalhos futuros devem mirar.

Referências

1. Bar-Shalom, Y., Li, X.-R., Kirubarajan, T.: Estimation with Applications to Tracking and Navigation: Theory, Algorithms and Software. Wiley, New York (2001)
2. Kluge, S., Reif, K., Brokate, M.: Stochastic stability of the extended Kalman filter with intermittent observations. *IEEE Transactions on Automatic Control* **55**(2), 514–518 (2010)
3. Li, L., Xia, Y.: Stochastic stability of the unscented Kalman filter with intermittent observations. *Automatica* **48**(5), 978–981 (2012)
4. Durrant-Whyte, H., Bailey, T.: Simultaneous localization and mapping (SLAM): Part I. *IEEE Robotics & Automation Magazine* **13**(2), 99–110 (2006)
5. Dissanayake, M.W.M.G., Newman, P., Clark, S., Durrant-Whyte, H.F., Csorba, M.: A solution to the simultaneous localization and map building (SLAM) problem. *IEEE Transactions on Robotics and Automation* **17**(3), 229–241 (2001)
6. Sinopoli, B., Schenato, L., Franceschetti, M., Poolla, K., Jordan, M.I., Sastry, S.S.: Kalman filtering with intermittent observations. *IEEE Transactions on Automatic Control* **49**(9), 1453–1464 (2004)
7. Censi, A.: Geometric remarks on Kalman filtering with intermittent observations. *arXiv:0906.1637* (2009)
8. Zhang, Z.: A flexible new technique for camera calibration. *IEEE Transactions on Pattern Analysis and Machine Intelligence* **22**(11), 1330–1334 (2000)
9. Altendorfer, R., Wirkert, S.J.: Why the association log-likelihood distance should be used for measurement-to-track association. In: 2016 IEEE Intelligent Vehicles Symposium (IV). pp. 258–265 (2016)
10. Khosravi, N., Khosravi, N., Bozorg, M., Bahraini, M.S.: Decentralized Cooperative Localization for Multi-Robot Systems with Asynchronous Sensor Fusion. *arXiv:2603.12075* (2026)
11. Ahmed, M.F., Frémont, V.: Decentralized Multi-Robot Obstacle Detection and Tracking in a Maritime Scenario. *arXiv:2602.12012* (2026)
12. Dobrynin, D., Garcia, I.T.: A TurtleBot3 Hardware Testbed for Distributed Kalman Filter Localization. Senior Project, California Polytechnic State University, San Luis Obispo (2025)
13. Leung, K.Y.K., Halpern, Y., Barfoot, T.D., Liu, H.H.T.: The UTIAS multi-robot cooperative localization and mapping dataset. *The International Journal of Robotics Research* **30**(8), 969–974 (2011)
14. Feng, D., Qi, Y., Zhong, S., Chen, Z., Chen, Q., Chen, H., Wu, J., Ma, J.: S3E: A multi-robot multimodal dataset for collaborative SLAM. *arXiv:2210.13723* (2022)

15. Sturm, J., Engelhard, N., Endres, F., Burgard, W., Cremers, D.: A benchmark for the evaluation of RGB-D SLAM systems. In: 2012 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS), pp. 573–580 (2012)