

Diagnóstico Causal de Desempenho de Aprendizado por Reforço em Alocação de Tarefas Multi-Robô por Visão Computacional com Gêmeo Digital

1º Yan Santos Leite

Escola de Engenharia Elétrica, Mecânica e de Computação
Universidade Federal de Goiás (UFG)

Goiânia, Brasil

santosleiteyan@gmail.com

2º Alisson Assis Cardoso

Escola de Engenharia Elétrica, Mecânica e de Computação
Universidade Federal de Goiás (UFG)

Goiânia, Brasil

alsnac@ufg.br

Abstract—A alocação de tarefas multi-robô (MRTA) costuma ser resolvida com heurísticas gulosas, rápidas mas incapazes de antecipar demandas futuras. Treinamos um agente de aprendizado por reforço (RL, Proximal Policy Optimization, PPO) para essa tarefa, com observações baseadas em um gêmeo digital por câmera: uma câmera overhead e um detector YOLOv8n localizam uma frota de robôs TurtleBot3 com erro médio de rastreamento de 4,7 cm ($mAP@0.5 = 0,995$), substituindo a odometria bruta como fonte de posição da política de alocação. Comparamos o PPO contra a heurística gulosa *nearest-free* usando testes estatísticos pareados rigorosos sobre 1000 episódios. Contrariando nossa hipótese, o PPO não superou o *nearest-free*: o tempo médio de resposta ficou cerca de 12% pior, uma diferença estatisticamente significativa. Descobrimos que o PPO atribui tarefas a robôs ocupados em 4,0% das decisões, contra 0,3% do *nearest-free* (13 vezes mais), sugerindo que a penalidade de treino não bastou para ensinar essa restrição. Testamos essa hipótese causalmente com *action masking*, que impede estruturalmente a política de escolher robôs ocupados: a taxa de atribuição inválida caiu para exatamente 0%, mas o tempo de resposta continuou cerca de 11% pior que o *nearest-free*. A violação de restrição, portanto, não é a causa dominante do gap. Reportamos esse resultado negativo e o diagnóstico de sua causa-raiz com rigor estatístico completo, argumentando que uma hipótese refutada, testada de forma transparente, é mais valiosa do que uma alegação positiva incompleta.

Index Terms—alocação de tarefas multi-robô, sistemas multi-robô, aprendizado por reforço profundo, proximal policy optimization, action masking, gêmeo digital, detecção de objetos, resultado negativo

I. INTRODUÇÃO

Coordenar uma frota de robôs móveis para atender demandas distribuídas no espaço e no tempo (alocação de tarefas multi-robô, MRTA) é um problema central em coordenação multi-robô [1], com aplicações que vão de robótica de serviço a automação de armazéns [10], [11]. Heurísticas gulosas como a atribuição ao robô livre mais próximo (*nearest-free*) são simples, rápidas e respeitam restrições operacionais (por exemplo, nunca atribuir um robô ocupado) por construção. O problema é que elas só olham para a demanda atual: atribuem o robô livre mais próximo sem considerar que esse mesmo robô pode ser necessário, de forma mais eficiente, para uma

demanda que vai chegar logo em seguida. O aprendizado por reforço (RL) é um candidato natural para corrigir essa miopia, já que uma política aprendida pode, em princípio, trocar uma atribuição localmente subótima por um resultado globalmente melhor.

Há um segundo desafio, em grande parte independente do primeiro. Para decidir qual robô enviar, o alocador precisa saber onde cada robô está agora, e descobrir isso em tempo real não é trivial nem gratuito. A odometria das rodas, o método mais simples, estima a posição a partir do quanto as rodas giraram e acumula erro ao longo do tempo. Métodos mais precisos, como SLAM (*Simultaneous Localization and Mapping*), corrigem esse erro, mas são caros de implantar em hardware real. Usamos uma alternativa de baixo custo: uma câmera fixa no teto, apontada para a área de operação, com um detector YOLOv8n que identifica cada robô na imagem. Chamamos esse sistema de *gêmeo digital*: ele publica a posição de cada robô em tempo real, sem acumular erro ao longo do tempo.

Este artigo traz duas contribuições. Primeiro, integramos e validamos esse gêmeo digital baseado em câmera (erro médio de localização de 4,7 cm, $mAP@0.5 = 0,995$) para alimentar as observações de um alocador baseado em RL, validando o pipeline completo em três robôs TurtleBot3 Waffle no Gazebo. Segundo, e mais importante, relatamos um *resultado negativo*: nosso agente treinado com PPO não supera a heurística *nearest-free*. Investigando o porquê, encontramos uma pista concreta: o PPO atribui tarefas a robôs ocupados 13 vezes mais que a heurística, o que parecia explicar o problema. Testamos essa explicação diretamente com *action masking*: em vez de só penalizar essa escolha na recompensa e esperar que o PPO aprendesse sozinho a evitá-la, passamos a remover os robôs ocupados da lista de opções válidas em cada decisão, tornando essa escolha impossível por construção (o mesmo princípio que já torna o *nearest-free* imune a esse erro). Descobrimos que essa correção estrutural não era a causa principal: o desempenho quase não melhorou. Esse processo completo, uma hipótese plausível testada e depois refutada com dados, é a principal contribuição deste trabalho: mostrar de forma

transparente não só que o método falhou, mas por que ele falhou.

II. TRABALHOS RELACIONADOS

Abordagens clássicas de MRTA usam leilões baseados em mercado [2], atribuição gulosa [1] e otimização centralizada, que oferecem garantias fortes de restrição, mas visão limitada de futuro. A alocação baseada em aprendizado também foi explorada em formulações multiagente com CTDE [3], além de configurações single-agent como a nossa. Reprodutibilidade e rigor de avaliação seguem sendo problemas abertos em RL profundo [5]: a variância entre execuções com sementes distintas pode, sozinha, produzir diferenças estatisticamente significativas, o que motiva testes de significância em vez de comparar apenas retornos médios, lacuna que preenchemos com testes pareados. Orr e Dutta [9] revisam aplicações de RL multiagente em sistemas multi-robô, identificando escalabilidade e a falta de benchmarks de simulação padronizados como desafios em aberto. Trabalhos recentes de RL em MRTA de armazém incluem abordagens descentralizadas baseadas em MDP [10] e frameworks duais [11]; diferentemente desses, nosso foco é diagnosticar por que uma política aprendida *não* supera uma heurística gulosa, via experimento causal (action masking). No lado da percepção, detectores da família YOLO [4] são comuns em rastreamento baseado em visão [12], mas trabalhos anteriores avaliam a detecção isoladamente, sem isolar seu efeito sobre uma política de alocação aprendida mantendo tudo o mais fixo, a ablação que rodamos aqui. O relato de resultados negativos permanece raro em robótica e RL; seguimos os chamados de Henderson et al. por avaliação estatística pareada rigorosa [5]. Nosso diagnóstico causal também se apoia em Huang e Ontañón [8], que mostram que *action masking* produz um gradiente de política válido e supera a penalização suave de ações inválidas. Diferente do domínio de RTS desses autores, onde masking fecha a lacuna de desempenho, no nosso domínio ele elimina a violação estrutural sem fechar o gap, evidência de que a causa subjacente é distinta.

III. GÊMEO DIGITAL E FORMULAÇÃO DE RL

O gêmeo digital consiste em uma câmera overhead montada estaticamente, um detector YOLOv8n ajustado sobre 375 frames anotados manualmente (um a três robôs TurtleBot3 Waffle), e um módulo de projeção de coordenadas que mapeia centros de *bounding box* para posições (x, y) no mundo, publicadas no tópico ROS2 `/robot_detections`. O detector atinge $mAP@0.5 = 0,995$ com inferência em 36 ms/frame em CPU. Um benchmark estático com 8 poses fixas dá erro médio de 1,24 cm; ao longo de uma sequência contínua de rastreamento (2031 amostras, navegação ao vivo sob Nav2) o erro médio é 4,7 cm, com 100% das detecções dentro de 15 cm do *ground truth* (Fig. 2), aumento de aproximadamente 4× do estático para o dinâmico consistente com motion blur e latência entre detecção e pose, não com limitação do detector. Esse erro dinâmico é o nível de precisão usado em todos os experimentos a jusante.




Fig. 1. Dois dos robôs TurtleBot3 Waffle da frota vistos pela câmera overhead: anotação *ground truth* (topo) vs. predição do detector (embaixo) em uma cena do conjunto de validação. Os experimentos completos com três robôs são quantificados nas Seções IV–V.




Fig. 2. Erro de localização do gêmeo digital ao longo de uma sequência contínua de rastreamento multi-robô. Erro médio de 4,7 cm; 100% das detecções dentro de 15 cm do *ground truth*.

Formulamos a alocação de tarefas como um Processo de Decisão de Markov (MDP): a cada chegada de demanda, um agente centralizado decide, com base no estado atual do sistema, qual dos $N = 3$ robôs vai atendê-la. O estado de 21 dimensões descreve tudo o que o agente observa naquele instante: a posição (x, y) de cada robô (do gêmeo digital ou da odometria, conforme o braço experimental), quanto tempo falta para cada robô ficar livre, a origem e o destino da demanda que acabou de chegar, e a origem e o destino das próximas duas demandas já visíveis na fila, um sinal de antecipação que permite ao agente considerar o impacto futuro de cada escolha, não só a demanda imediata. A ação é a escolha discreta de qual desses N robôs deve atender a demanda atual. A recompensa é o tempo de resposta negativo $r = -(t_{espera} + t_{deslocamento})$: quanto mais rápido a demanda é atendida, da chegada até o robô escolhido começar a executá-la, maior a recompensa. Isso corrige uma formulação anterior que penalizava só o deslocamento até a demanda, ignorando quanto tempo o robô escolhido ainda levaria para ficar livre; sob essa formulação antiga, um robô ocupado e próximo podia parecer tão bom quanto um robô livre e distante, o que dava peso insuficiente aos efeitos de fila e enviesava a política para robôs livres, porém distantes. Treinamos com PPO [6] via Stable-Baselines3 [7] por 500.000 timesteps (~ 2 h em CPU), nos hiperparâmetros padrão da biblioteca (Tabela I) para isolar o efeito da fonte de observação e do masking, não o de ajuste fino do PPO; o Gazebo é reservado para validação física de estágio final, não para treino. Ambas as variantes de PPO aprendem (Fig. 3): a recompensa média melhora de ~ -21 para $\sim -17,7$ ao longo de 500k passos, mas nenhuma cruza a linha de referência do nearest-free ($-16,7$); o PPO(odom) converge um pouco mais rápido, confirmando que o ruído de 4,7 cm do gêmeo digital é um efeito de segunda ordem.

TABLE I
HIPERPARÂMETROS DE TREINO (IDÊNTICOS EM TODAS AS VARIANTES)

Hiperparâmetro	Valor
Política / rede	MlpPolicy, $\pi=[64,64]$, $V=[64,64]$
Taxa de aprendizado	3×10^{-4}
n_{steps} (por ambiente) / batch	2048 / 64
γ / GAE λ / clip range	0,99 / 0,95 / 0,2
Ambientes paralelos / semente	8 / 42

IV. SETUP EXPERIMENTAL

Comparamos o PPO contra três baselines: *random* e *round-robin*, que servem como piso de desempenho por não terem nenhuma noção de proximidade ou fila, e *nearest-free*, que atribui o robô livre mais próximo e é inviável por construção quando nenhum robô está livre. Para isolar o efeito do gêmeo digital, treinamos PPO(YOLO) e PPO(odom), idênticos exceto pela fonte de posição usada na observação (ruído gaussiano de 4,7 cm no YOLO vs. drift acumulado de odometria no odom); usar sementes pareadas entre as duas variantes garante que a única diferença entre elas seja essa fonte de ruído, não a sorte do treino. Cada comparação avalia 1000 episódios




Fig. 3. Curvas de aprendizado do PPO para as variantes de observação YOLO e odometria, com o baseline nearest-free como linha de referência.

pareados, usando a mesma sequência de demandas e semente para ambas as políticas, o que nos permite reportar não só se a diferença é estatisticamente significativa (Wilcoxon signed-rank) mas também seu tamanho de efeito (delta de Cliff) e incerteza (intervalos de confiança bootstrap). Para verificar se essas conclusões se sustentam sob diferentes pressões de demanda, um sweep de carga cobre seis regimes de intervalo entre chegadas, de 30s a 10s (500 episódios/ponto). O pipeline completo, da câmera ao YOLO, passando pelo alocador e pelo Nav2, até os robôs TurtleBot3 Waffle, foi validado de ponta a ponta em três robôs no Gazebo Classic (ROS2 Humble); a política de RL em si, porém, só é treinada no ambiente analítico. Para testar causalmente se a restrição suave de nunca atribuir um robô ocupado é a causa do desempenho ruim do PPO, treinamos também PPO(YOLO, masked): idêntico ao PPO(YOLO) exceto que a distribuição de ação é restrita, a cada passo, aos robôs atualmente livres, via *action masking* [8] usando o MaskablePPO da sb3-contrib, com os mesmos hiperparâmetros e orçamento de treino. Omitimos uma variante PPO(odom, masked) já que o efeito do ruído do gêmeo digital já se mostrou de segunda ordem (Seção V), então testá-la não mudaria a conclusão qualitativa do experimento.

V. RESULTADOS

A Tabela II resume o desempenho em carga moderada: o nearest-free supera ambas as variantes de PPO nas quatro métricas reportadas (latência média, p95, makespan e desbalanceamento de carga), e o gap entre PPO(YOLO) e PPO(odom) é pequeno frente ao quanto qualquer uma das duas fica atrás do nearest-free, confirmando que o ruído do gêmeo digital é um efeito de segunda ordem. O teste de Wilcoxon confirma que essa vantagem é estatisticamente significativa em ambas as comparações ($p < 0,001$, delta de Cliff grande). Numa análise complementar, focada especificamente nas decisões em que PPO e nearest-free escolhem robôs diferentes, o nearest-free acerta a opção melhor em 72% desses casos (2000 episódios). A razão p95/latência média também é semelhante entre as três políticas ($\approx 1,56$ – $1,59$, Fig. 4), indicando que o desempenho pior do PPO vem de um deslocamento de toda a distribuição de tempo de resposta, não de uma cauda de poucos episódios catastróficos puxando a média para baixo.

TABLE II
COMPARAÇÃO DE POLÍTICAS EM CARGA MODERADA (INTER-ARRIVAL
12S, 1000 EPISÓDIOS PAREADOS)

Política	Lat. média	Lat. p95	Makespan	Desbal.
Nearest-free	16,83 s	26,73 s	336,58 s	0,24
PPO (YOLO)	17,83 s	27,84 s	356,63 s	0,32
PPO (odom)	17,12 s	27,18 s	342,34 s	0,31




Fig. 4. Distribuição de tempo de resposta entre as políticas avaliadas, incluindo a variante PPO mascarada.

A Tabela III e a Fig. 5 mostram que a desvantagem do PPO em relação ao nearest-free diminui conforme a carga aumenta, de +19,0% em carga baixa para +7,7% em carga alta, embora o nearest-free permaneça mais rápido em toda a faixa testada.




Fig. 5. Tempo de resposta em função da carga de demanda (inter-arrival) para nearest-free e PPO(YOLO).

VI. DIAGNOSTICANDO O RESULTADO NEGATIVO

O PPO aprende, e ainda recebe um lookahead de duas demandas que o baseline guloso não tem, mas mesmo assim não supera o nearest-free. Investigamos três explicações. Imposição de restrição suave vs. rígida: o nearest-free nunca atribui um robô ocupado, pois essa restrição está embutida no

TABLE III
TEMPO DE RESPOSTA POR POLÍTICA ENTRE REGIMES DE CARGA

Inter-arrival	Nearest-free	PPO(YOLO)	Diferença
30 s (baixa)	333,8 s	397,3 s	+19,0%
12 s (mod.)	355,4 s	399,1 s	+12,3%
10 s (alta)	371,1 s	399,8 s	+7,7%

próprio algoritmo; o PPO só consegue aprender a evitar isso indiretamente via penalidade na recompensa, e ainda assim erra em 4,0% das decisões, contra 0,3% do nearest-free, o maior contribuinte isolado que encontramos. Espaço de ação limitado: com apenas $N = 3$ robôs, poucas combinações de atribuição são significativamente diferentes, limitando qualquer vantagem antecipatória; nosso orientador corroborou esse ponto como fator plausível, porém secundário. Orçamento de treino: 500k passos produziram aprendizado claro, mas não convergência, embora o próprio tempo de resposta do PPO fique quase estável entre regimes de carga (397–400 s, Tabela III) enquanto o do nearest-free cresce bastante em carga alta, sugerindo que o platô não é só um artefato de orçamento.

Teste causal. Para testar diretamente se essa violação de restrição era a causa, treinamos o PPO(YOLO, masked) e o reavaliamos junto com o PPO(YOLO) não-mascarado e o nearest-free sobre um novo conjunto de 1000 episódios em carga moderada, todos na mesma rodada de avaliação. O masking cumpre sua função por construção: a taxa de atribuição inválida cai de 4,0% para exatamente 0,0%. Mas o tempo médio de resposta melhora pouco, de cerca de 12% pior que o nearest-free (não-mascarado) para cerca de 11% pior (mascarado), uma melhora de aproximadamente 1 ponto percentual. O nearest-free ainda supera significativamente a variante mascarada ($p < 0,001$, delta de Cliff = 0,636), tamanho de efeito da mesma ordem de grandeza do não-mascarado ($\delta = 0,703$).

A hipótese causal é refutada. A explicação que parecia mais plausível a priori não se sustenta: eliminar a violação por construção quase não fecha o gap. O peso volta para o espaço de ação pequeno e o orçamento de treino, e surge uma explicação adicional: o masking remove não só a violação, mas também qualquer sinal de aprendizado sobre sua consequência, o que pode reduzir a diversidade de exploração da política sem compensar com vantagem real de antecipação. Reportamos essa refutação com o mesmo rigor estatístico do resultado original, pois um experimento causal negativo é tão informativo quanto um positivo.

VII. CONCLUSÃO E TRABALHOS FUTUROS

Apresentamos um framework de ponta a ponta integrando um gêmeo digital baseado em câmera, validado, com um alocador de tarefas multi-robô baseado em PPO. Contrariando nossa hipótese, o PPO não superou o nearest-free. Uma taxa de atribuição inválida $\sim 13\times$ maior sob o PPO era a principal suspeita; testá-la causalmente com action masking a refutou: eliminar a violação por construção fecha apenas cerca de 1 dos aproximadamente 12 pontos percentuais que separam o

PPO do nearest-free. A causa dominante está no espaço de ação pequeno e/ou no orçamento de treino, não na imposição suave da restrição. Trabalhos futuros incluem um dataset de validação física maior, um espaço de ação maior para testar essa hipótese diretamente, revisitar a arquitetura da política (MLP simples vs. arquiteturas especializadas usadas em trabalhos recentes de RL para MRTA), e reformular a formulação centralizada como um Dec-POMDP sob *Centralized Training with Decentralized Execution* [3].

AGRADECIMENTOS

Os autores agradecem à Universidade Federal de Goiás pela infraestrutura utilizada neste trabalho.

REFERENCES

- [1] B. P. Gerkey and M. J. Mataric, "A formal analysis and taxonomy of task allocation in multi-robot systems," *Int. J. Robot. Res.*, vol. 23, no. 9, pp. 939–954, 2004.
- [2] M. B. Dias, R. Zlot, N. Kalra, and A. Stentz, "Market-based multirobot coordination: A survey and analysis," *Proc. IEEE*, vol. 94, no. 7, pp. 1257–1270, 2006.
- [3] R. Lowe, Y. Wu, A. Tamar, J. Harb, P. Abbeel, and I. Mordatch, "Multi-agent actor-critic for mixed cooperative-competitive environments," in *Proc. NeurIPS*, 2017.
- [4] G. Jocher, A. Chaurasia, and J. Qiu, "Ultralytics YOLO," 2023. [Online]. Available: <https://github.com/ultralytics/ultralytics>. Accessed: Jul. 15, 2026.
- [5] P. Henderson, R. Islam, P. Bachman, J. Pineau, D. Precup, and D. Meger, "Deep reinforcement learning that matters," in *Proc. AAAI*, 2018.
- [6] J. Schulman, F. Wolski, P. Dhariwal, A. Radford, and O. Klimov, "Proximal policy optimization algorithms," 2017, arXiv:1707.06347.
- [7] A. Raffin, A. Hill, A. Gleave, A. Kanervisto, M. Ernestus, and N. Dormann, "Stable-Baselines3: Reliable reinforcement learning implementations," *J. Mach. Learn. Res.*, vol. 22, no. 268, pp. 1–8, 2021.
- [8] S. Huang and S. Ontañón, "A closer look at invalid action masking in policy gradient algorithms," in *Proc. Int. FLAIRS Conf.*, vol. 35, 2022.
- [9] J. Orr and A. Dutta, "Multi-agent deep reinforcement learning for multi-robot applications: A survey," *Sensors*, vol. 23, no. 7, p. 3625, 2023.
- [10] A. Agrawal, S. Hariharan, A. S. Bedi, and D. Manocha, "DC-MRTA: Decentralized multi-robot task allocation and navigation in complex environments," in *Proc. IEEE/RSJ Int. Conf. Intell. Robots Syst. (IROS)*, 2022, pp. 11711–11718.
- [11] A. Pal, A. Chauhan, and M. Baranwal, "Together we rise: Optimizing real-time multi-robot task allocation using coordinated heterogeneous plays," in *Proc. Int. Conf. Auton. Agents Multiagent Syst. (AAMAS)*, 2025.
- [12] I. Ahmed, S. Din, G. Jeon, F. Piccialli, and G. Fortino, "Towards collaborative robotics in top view surveillance: A framework for multiple object tracking by detection using deep learning," *IEEE/CAA J. Autom. Sinica*, vol. 8, no. 7, pp. 1253–1270, 2021.