

# CERISE — Dois Trabalhos, Uma Base Comum

LARS 2026 (alocação de tarefas via RL) e LAFusion 2026 (fusão sensorial via EKF)

Yan Santos Leite

Orientador: Prof. Alisson Assis Cardoso

Escola de Engenharia Elétrica, Mecânica e de Computação (EMC) — UFG  
Fundação de Amparo à Pesquisa do Estado de Goiás (FAPEG)

16 de agosto de 2026

# Roteiro e visão geral dos dois trabalhos

Esta apresentação cobre a trajetória completa de dois trabalhos que compartilham a mesma base de código e a mesma plataforma física (três TurtleBot3 no CERISE), mas respondem a perguntas de pesquisa diferentes: (1) LARS 2026, da concepção à submissão (06/08); (2) LAFusion 2026, da concepção ao estado atual (16/08); (3) Conclusão, com próximos passos de cada um.

|            | <b>LARS 2026</b>                                      | <b>LAFusion 2026</b>                                              |
|------------|-------------------------------------------------------|-------------------------------------------------------------------|
| Pergunta   | RL supera a heurística gulosa na alocação de tarefas? | Como o EKF se comporta quando a taxa de detecção do YOLO é baixa? |
| Método     | PPO (Stable-Baselines3)                               | Extended Kalman Filter por robô                                   |
| Plataforma | 3 TurtleBot3, ROS2/Gazebo                             | 3 TurtleBot3, ROS2/Gazebo                                         |
| Estado     | Submetido no EasyChair em 06/08                       | Prazo de submissão 04/09                                          |

# Tese, argumentação e contribuições

**Tese central.** Rigor metodológico (teste causal, fundamentação teórica explícita) vale mais que uma alegação de vitória não testada, mesmo com resultado central negativo ou misto.

## Como a tese se sustenta:


- ▶ **LARS:** testa a hipótese de que RL supera a heurística, encontra o oposto, e usa um experimento causal (*action masking*) para refutar a explicação mais plausível a priori.
- ▶ **LAFusion:** não reporta só o ganho de +23,7% pontual; mede também a degradação de -12,7% contínua sob baixa taxa de detecção do YOLO e explica a reversão com teoria prévia de filtragem sob observação intermitente.

**Contribuições:** (1) gêmeo digital câmera+YOLO validado ( $mAP@0,5=0,995$ , erro 4,7 cm), base comum aos dois trabalhos; (2) diagnóstico causal de por que PPO perde em MRTA com  $N=3$ , isolando o espaço de ação pequeno como fator dominante; (3) EKF avaliado sob baixa taxa de detecção do YOLO: +23,7% de ganho nos instantes de correção, -12,7% de erro medido continuamente.


# LARS — Motivação, arquitetura e gêmeo digital

O problema. MRTA (*Multi-Robot Task Allocation*: decidir qual robô de uma frota atende cada demanda que chega) é resolvida na prática por heurísticas gulosas (robô livre mais próximo, míopes a demandas futuras). Hipótese: PPO com antecipação de duas demandas futuras supera a heurística *nearest-free* em tempo de resposta.


Treino (offline, sem câmera):



Inferência (produção, ROS2):



`rl/allocation_env.py`: ambiente Gymnasium *analítico* (sem ROS/Gazebo), `step()` é aritmética pura, treina 500k timesteps em minutos em vez de dias — não recebe dados da câmera. Em produção, `rl_task_allocator.py` carrega o modelo já treinado e consome `/robot_detections` diretamente. `task_allocator.py`: heurística baseline (linha tracejada).



|               |         |
|---------------|---------|
| mAP@0.5       | 0,995   |
| Erro estático | 1,24 cm |
| Erro dinâmico | 4,7 cm  |
| Det. < 15 cm  | 100%    |

É o erro de 4,7 cm (rastreamento contínuo) que alimenta os experimentos seguintes, não o estático — salto vem de motion blur e latência, não de limitação do detector. Verdade/predição bem comportadas mesmo com múltiplos robôs próximos (evidência qualitativa contra outliers escondidos pela média).

# LARS — Formulação do MDP e protocolo experimental

**Estado (21D):**  $3N + 4 + 4 \times 2$  para  $N = 3$ : posição/tempo-livre de cada robô, origem/destino da demanda atual e das **2 próximas** já visíveis na fila (a antecipação, sem a qual a política não teria como decidir “*segurar*” um robô livre). **Ação:** escolha discreta de qual robô atende a demanda. **Recompensa:**  $r = -(t_{espera} + t_{viagem})$ , o tempo de resposta completo — a formulação original penalizava só o tempo de viagem, um bug de causa-raiz corrigido antes do primeiro resultado válido.

**Treino:** PPO/Stable-Baselines3, hiperparâmetros padrão ( $\log 3 \times 10^{-4}$ ,  $\gamma = 0,99$ , 8 envs paralelos, seed 42), 500k timesteps ( $\sim 2$ h CPU). Defaults isolam o efeito da fonte de observação e do masking, não buscam o teto de desempenho do PPO.



**Estatística:** 1000 episódios pareados, Wilcoxon signed-rank, Cliff’s  $\delta$ , IC 95% bootstrap. Pareamento é necessário porque a variância entre sementes já produz diferenças significativas em RL profundo.

**Robustez:** 6 regimes de carga (30s–10s), 500 episódios/ponto. **Por quê PPO e não SAC/DQN:** o experimento isola fonte de observação e masking sobre um único algoritmo, não faz benchmark de arquiteturas; PPO é o padrão de fato em SB3 com suporte nativo a masking (MaskablePPO), necessário para o teste causal a seguir.

# LARS — Resultado: achado negativo e robustez

| Política     | Resp.   | p95     | Desbal.      |
|--------------|---------|---------|--------------|
| Nearest-free | 17,86 s | 27,77 s | 0,149        |
| PPO (YOLO)   | 20,01 s | 29,46 s | <b>0,135</b> |
| PPO (odom)   | 19,83 s | 29,37 s | <b>0,135</b> |

Carga moderada, 1000 ep. pareados, Wilcoxon  $p < 0,001$ . **O guloso vence**: tempo de resposta  $\sim 12\%$  **pior** para o PPO. A proximidade entre PPO(YOLO) e PPO(odom) indica que o ruído do gêmeo digital é efeito de segunda ordem, não a causa.



O boxplot mostra p95/média comparável entre políticas ( $\approx 1,47-1,56$ ): a desvantagem vem de deslocamento de toda a distribuição, não de cauda catastrófica. Sob carga, o gap encolhe de  $+19,0\%$  para  $+7,7\%$ , mas o guloso permanece mais rápido em todo o intervalo testado.

# LARS — Diagnóstico causal, limitações e fechamento

Três explicações investigadas: (1) restrição suave vs. rígida: o guloso nunca escolhe robô ocupado por construção; o PPO erra em 4,2% das decisões contra 0,3% do guloso ( $\sim 13\times$  mais), o maior contribuinte isolado; (2) espaço de ação pequeno: com  $N = 3$ , no máximo três alternativas por decisão; (3) orçamento de treino: aprendizado claro, mas sem convergência.

Teste causal: PPO(YOLO, masked), ação restrita a robôs livres via *action masking* (MaskablePPO), mesmos hiperparâmetros e orçamento.


|                             | Sem masking | Com masking |
|-----------------------------|-------------|-------------|
| Taxa de ação inválida       | 4,2%        | 0,0%        |
| Gap vs. guloso              | $\sim 12\%$ | $\sim 11\%$ |
| Cliff's $\delta$ vs. guloso | 0,703       | 0,636       |

Hipótese causal refutada: o masking zera a taxa de ação inválida, mas o gap melhora só  $\sim 1$  ponto percentual. O peso volta para o espaço de ação pequeno e o orçamento de treino.

Limitações assumidas: (1) hiperparâmetros padrão do PPO, não o teto do RL para o problema; (2)  $N = 3$ , não extrapolar para frotas grandes; (3) sem validação em hardware físico; (4) 500k timesteps sem convergência. Todas são alvo direto de trabalho futuro. Revisão de literatura: 330 estudos triados (Scopus, IEEE, arXiv, ACM)  $\rightarrow$  117 aceitos / 213 rejeitados. Submissão: 06/08/2026, EasyChair; aceite previsto 15/09/2026. Título já declara o método (*Causal Diagnosis...*), não uma alegação de vitória do RL.

Por que um segundo paper: o LARS usa a posição do YOLO como estado observado, mas nunca pergunta o que fazer quando a detecção não está disponível. Em produção, um fallback discreto descarta informação (sem correção parcial, sem propagação formal de incerteza). A pergunta do LAFusion: como se comporta um EKF que funde as duas fontes probabilisticamente quando a taxa de detecção do YOLO é baixa?

# LA Fusion — Arquitetura e pipeline



## Módulos reais do código:

- ▶ `ekf_fusion_node.py`: nó ROS2 de produção. Um EKF independente por robô, predição via odometria, correção via detecção YOLO.
- ▶ `association.py`: gating de Mahalanobis compartilhado entre o EKF e o nó de avaliação offline.
- ▶ `projection.py`: projeção pixel↔mundo, com duas implementações confirmadas geometricamente equivalentes (heurística por FOV e via intrínsecos calibrados).



# LA Fusion — Design do EKF

**Estado:**  $x_k = [p_x, p_y, \theta]^\top$  por robô. A predição integra o *delta* de leituras consecutivas de odometria sobre o estado atual — não o valor absoluto, que descartaria correções visuais anteriores.

## Hiperparâmetros e sua origem:

- ▶  $Q = \text{diag}(0,5, 0,5, 0,25)$  — calibrado empiricamente contra dados reais (varredura de  $10^{-6}$  a 1,0; ganho cresce monotonicamente até saturar em  $Q \geq 0,5$ ).
- ▶ Teto de covariância  $\text{clip}(P, -\infty, 0,05)$ : *sem* ele,  $P$  crescia sem limite em intervalos longos sem correção (traço observado  $\approx 85$  contra esperado  $\approx 0,5$ ), quebrando o gating de Mahalanobis ao alargar a região de aceitação até um robô “roubar” a detecção do vizinho.
- ▶ Limiar de gating  $d^2 \leq 9,21$  — valor padrão do teste  $\chi^2$  com 2 graus de liberdade a 99% de confiança, não um número ajustado ad hoc.
- ▶ Atualização de  $P$  via **forma de Joseph**  $(I - KH)P(I - KH)^\top + K RK^\top$ , e gating com  $S = P + R$  (não só  $P$ ) — duas correções de rigor numérico aplicadas nesta sessão (17/08/2026), sem alterar nenhum resultado já publicado.

*Por quê o teto de covariância existe:* mantém a associação estável, não torna a estimativa de estado mais precisa durante o intervalo sem correção. É uma distinção central para a escolha do próximo bloco de slides.

# LA Fusion — Testes e validação


**Validação sintética (antes de qualquer dado real):** Monte Carlo com 30 sementes, 2000 passos cada, contra trajetória sintética com verdade terrestre conhecida.

| Estat. | Obtido | Esperado   |
|--------|--------|------------|
| NEES   | 2,955  | 3,0 (1,5%) |
| NIS    | 1,982  | 2,0 (0,9%) |

*Por quê validar sinteticamente antes do dado real:* isola bugs de implementação de problemas de dado — um filtro mal calibrado contra dados sintéticos jamais seria confiável contra dados reais mais ruidosos.

**Dados reais:** 3 cenários gravados no Gazebo (parado, reto, curva/oclusão), 3 robôs, sincronização de timestamp verificada (nenhum gap >500ms).

**Sobre benchmarks públicos:** não avaliamos contra UTIAS MRCLAM ou S3E — ambos assumem sensor embarcado em cada robô (range-bearing ou LiDAR/estéreo/IMU onboard); nosso cenário usa câmera externa



NEES/NIS ao longo dos 2000 passos, com valor esperado teórico e faixa de confiança 95%: a tabela ao lado é só a média agregada das 30 sementes; esta figura confirma que a consistência do filtro se mantém estável do início ao fim da corrida, não só num regime transitório, antes de aplicá-lo aos dados reais.


# LA Fusion — Resultado principal

| Drift     | Méd. EKF/Odom | $\Delta$ | RMSE EKF/Odom |
|-----------|---------------|----------|---------------|
| Nenhum    | 0,036/0,000   | N/A      | 0,052/0,000   |
| Leve      | 0,053/0,050   | -5,3%    | 0,068/0,066   |
| Agressivo | 0,128/0,168   | +23,7%   | 0,163/0,195   |

**Table:** Erro de posição (m) nos instantes de correção YOLO, 3 cenários ( $n = 1323$ ). Wilcoxon  $p < 0,001$  sob drift agressivo.

Sob drift agressivo, o EKF reduz o erro médio em **+23,7%** frente à odometria pura.

*Por quê o ganho é negativo sob drift leve (-5,3%):* o erro de detecção visual ( $\approx 3-6$  cm) ainda não é menor que o erro de odometria pouco corrompida nesse regime. Fundir as duas não ajuda, e pode piorar levemente. É comportamento esperado de um filtro corretamente calibrado, não uma falha.



Cenário 2 (preto) sob drift agressivo: EKF (azul) vs. odometria com drift (laranja, tracejada) vs. verdade terrestre (preto). A tabela reduz o ganho a um número agregado; aqui está o mecanismo — a odometria se afasta do caminho real enquanto o EKF permanece próximo, evidência qualitativa de que o filtro corrige o drift, não só que a métrica agregada melhorou.

# LA Fusion — Achado central: o erro contínuo

| Cenário         | Cobertura | Média EKF/Odom       | $\Delta$      | RMSE EKF/Odom        | $\Delta$ RMSE |
|-----------------|-----------|----------------------|---------------|----------------------|---------------|
| Parado          | 27,6%     | 0,212 / 0,177        | −19,3%        | 0,246 / 0,205        | −19,8%        |
| Reto            | 11,3%     | 0,212 / 0,178        | −18,8%        | 0,245 / 0,206        | −19,2%        |
| Curva/occlusão  | 0,0%      | 0,178 / 0,178        | −0,0%         | 0,205 / 0,205        | −0,0%         |
| <b>Agregado</b> | —         | <b>0,200 / 0,178</b> | <b>−12,7%</b> | <b>0,233 / 0,205</b> | <b>−13,4%</b> |


**Table:** Erro medido a CADA leitura de odometria, não só nos instantes de correção ( $n = 1607$ , Wilcoxon  $p < 0,001$ ).

Medido continuamente, o mesmo filtro é **12,7% pior** que odometria pura: sinal invertido em relação ao slide anterior. No cenário de 0% de cobertura, a mudança é exatamente 0,0%: sem correções, a predição do EKF degenera matematicamente para integração pura de delta-odometria, idêntica à baseline não fundida. É confirmação, não coincidência.

**ATE vs. RPE (Sturm et al. 2012):** o erro acima é ATE (erro absoluto por amostra). RPE (drift entre passos consecutivos) também piora, mas bem menos (−4,2%/ − 4,8% agregado) — a reversão vem sobretudo de erro *acumulando* sob correção esparsa, não de cada passo individual driftando muito mais que a odometria.

**Isso não invalida a contribuição:** reportar as duas métricas, em vez de só a favorável, é o ponto do trabalho, não uma admissão de fracasso.

# LA Fusion — Por que o erro contínuo piora (fundamentação teórica)



A covariância satura no teto quase imediatamente após qualquer intervalo sem correção (Sinopoli et al. 2004: divergência de covariância abaixo de uma taxa crítica de observação; nosso cenário de 0% de cobertura está no caso-limite  $p \rightarrow 0$ ). O teto evita crescimento ilimitado, mas capta a *estimativa de incerteza do próprio filtro*, não torna a estimativa de estado mais precisa: o filtro fica excessivamente confiante na predição só-odometria. Dissanayake et al. (2001) provam convergência do EKF-SLAM sob observação *densa*; nossa câmera viola essa premissa por construção (0–28% de cobertura).

**Por que UKF/partículas/IMM não resolvem:** um filtro de partículas degenera para propagação pura sem verossimilhança para reponderar; um UKF mira não-linearidade do modelo de observação, não a taxa de observação; um IMM ainda precisa de alguma observação para ponderar modos concorrentes. A causa raiz é a topologia do sensor (viewpoint único sujeito a oclusão), não a escolha do filtro.

# LA Fusion — Estado atual: correção da calibração de câmera

**Achado desta sessão (16/08):** a calibração original, com os 4 intrínsecos livres ( $f_x, f_y, c_x, c_y$ ), estava mal-condicionada —  $f_x$  33% acima do valor geometricamente esperado, apesar de erro de reprojeção baixo (0,162px).

*Causa raiz:* com a câmera fixa olhando reto para baixo, o tabuleiro de calibração fica sempre fronto-paralelo ao sensor em todas as poses. É o caso degenerado clássico do método de Zhang (2000): sem variação de inclinação relativa entre sensor e alvo,  $f_x$  e a distância percebida ficam quase linearmente dependentes.

**Correção aplicada:** como a geometria da câmera simulada já era conhecida com precisão (altura e campo de visão nominais exatos), fixamos  $f_x, f_y, c_x, c_y$  no valor geométrico nominal e calibramos apenas a distorção — o remédio padrão quando os intrínsecos nominais já são confiáveis.

**Resultado:** a calibração corrigida reproduz a projeção heurística já usada em produção a menos de 0,001m de diferença, confirmando equivalência geométrica. **Nenhum resultado já publicado no paper muda:** a heurística de produção nunca esteve errada, só uma calibração alternativa em teste estava mal-condicionada.

**Estado:** paper com 8 páginas escritas (limite real do CFP é 12), prazo de submissão **04/09/2026**, formato Springer CCIS, revisão double-blind via Microsoft CMT.

# Referências-chave e próximos passos

## LARS — bibliografia essencial:

- ▶ Henderson et al. (2018): reprodutibilidade em RL profundo, motiva o teste pareado.
- ▶ Huang & Ontañón (2022): action masking produz gradiente válido; no nosso domínio elimina a violação sem fechar o gap.
- ▶ Agrawal et al. (2023, RTAW), Paul et al. (2022, Capsule Attention): arquiteturas atencionais como direção futura.

Próximos passos: aguardar aceite (15/09/2026); espaço de ação e orçamento de treino maiores; formulação Dec-POMDP (CTDE).

## LA Fusion — bibliografia essencial:

- ▶ Sinopoli (2004), Bailey & Durrant-Whyte (2006), Dissanayake et al. (2001): fundamentação teórica clássica do achado central (erro contínuo, modelo EKF, convergência sob observação densa).
- ▶ Khosravi et al. (2026): localização cooperativa com fusão assíncrona, cenário mais próximo do nosso.
- ▶ Ahmed & Frémont (2026): rastreamento multi-robô descentralizado, mesma classe de problema.
- ▶ Dobrynin & Garcia (2025): testbed TurtleBot3 com EKF distribuído.

Próximos passos: submissão no CMT até 04/09/2026;  $Q$  adaptativo por tempo desde a última correção; Jacobiano completo na projeção; associação robusta (Hungarian/JPDA); LiDAR como terceira fonte.

---

**Conclusão — LARS:** resultado negativo testado e explicado causalmente; o *action masking* refuta a explicação mais plausível a priori, redirecionando o diagnóstico para o espaço de ação pequeno e o orçamento de treino.

**LA Fusion:** ganho real nos instantes de correção (+23,7%), mas mensuravelmente pior que odometria pura avaliado continuamente (−12,7%), reversão explicada pela teoria estabelecida de filtragem sob observação intermitente, não uma falha de implementação. Os dois trabalhos compartilham o mesmo padrão: reportar o resultado completo, favorável ou não, e fundamentá-lo.