

CERISE — Dois Trabalhos, Uma Base Comum

LARS 2026 (alocação de tarefas via RL) e LAFusion 2026 (fusão sensorial via EKF)

Yan Santos Leite

Orientador: Prof. Alisson Assis Cardoso

Escola de Engenharia Elétrica, Mecânica e de Computação (EMC) — UFG
Fundação de Amparo à Pesquisa do Estado de Goiás (FAPEG)

16 de agosto de 2026

Roteiro e visão geral dos dois trabalhos

Esta apresentação cobre a trajetória completa de dois trabalhos que compartilham a mesma base de código e a mesma plataforma física (três TurtleBot3 no CERISE), mas respondem a perguntas de pesquisa diferentes: (1) LARS 2026, da concepção à submissão (06/08); (2) LAFusion 2026, da concepção ao estado atual (16/08); (3) Conclusão, com próximos passos de cada um.

	LARS 2026	LAFusion 2026
Pergunta	RL supera a heurística gulosa na alocação de tarefas?	Como o EKF se comporta quando a taxa de detecção do YOLO é baixa?
Método	PPO (Stable-Baselines3)	Extended Kalman Filter por robô
Plataforma	3 TurtleBot3, ROS2/Gazebo	3 TurtleBot3, ROS2/Gazebo
Estado	Submetido no EasyChair em 06/08	Prazo de submissão 04/09

Tese, argumentação e contribuições

Tese central. Rigor metodológico (teste causal, fundamentação teórica explícita) vale mais que uma alegação de vitória não testada, mesmo com resultado central negativo ou misto.

Como a tese se sustenta:


- ▶ **LARS:** testa a hipótese de que RL supera a heurística, encontra o oposto, e usa um experimento causal (*action masking*) para refutar a explicação mais plausível a priori.
- ▶ **LAFusion:** não reporta só o ganho de +23,7% pontual; mede também a degradação de -12,7% contínua sob baixa taxa de detecção do YOLO e explica a reversão com teoria prévia de filtragem sob observação intermitente.

Contribuições: (1) gêmeo digital câmera+YOLO validado ($mAP@0,5=0,995$, erro 4,7 cm), base comum aos dois trabalhos; (2) diagnóstico causal de por que PPO perde em MRTA com $N=3$, isolando o espaço de ação pequeno como fator dominante; (3) EKF avaliado sob baixa taxa de detecção do YOLO: +23,7% de ganho nos instantes de correção, -12,7% de erro medido continuamente.


LARS — Motivação e arquitetura

O problema. MRTA (*Multi-Robot Task Allocation*: decidir qual robô de uma frota atende cada demanda que chega) é resolvida na prática por heurísticas gulosas (robô livre mais próximo, míopes a demandas futuras). **Hipótese:** PPO com antecipação de duas demandas futuras supera a heurística *nearest-free* em tempo de resposta.

Treino (offline, sem câmera):




Inferência (produção, ROS2):



`rl/allocation_env.py`: ambiente Gymnasium (biblioteca padrão para treino de RL: define `reset()/step(ação)` que qualquer algoritmo, aqui PPO, sabe treinar contra) *analítico* (sem ROS/Gazebo) — `step()` é aritmética pura, treina 500k timesteps em minutos em vez de dias, e não recebe dados da câmera.

LARS — Gêmeo digital: erro de localização câmera+YOLO




mAP@0.5	0,995
Erro estático	1,24 cm
Erro dinâmico	4,7 cm
Det. <15 cm	100%

É o erro de 4,7 cm (rastreo contínuo) que alimenta os experimentos seguintes, não o estático — salto vem de motion blur e latência, não de limitação do detector. Verdade/predição bem comportadas mesmo com múltiplos robôs próximos (evidência qualitativa contra outliers escondidos pela média).

LARS — Por que PPO $\neq$ nearest-free na prática

Comparação de políticas — seed=0



Mesmo estado (3 robôs, mesma demanda D), gerado a partir do AllocationEnv real: *nearest_free* sempre escolhe o robô livre mais próximo por construção (R2, esquerda); o PPO treinado pode escolher diferente (R1, direita) ao antecipar as 2 próximas demandas da fila — a divergência de decisão que a hipótese central do LARS testa.

LARS — Formulação do MDP e protocolo experimental

Estado (21D): $3N + 4 + 4 \times 2$ para $N = 3$: posição/tempo-livre de cada robô, origem/destino da demanda atual e das **2 próximas** já visíveis na fila (a antecipação, sem a qual a política não teria como decidir “*segurar*” um robô livre). **Ação:** escolha discreta de qual robô atende a demanda. **Recompensa:** $r = -(t_{espera} + t_{viagem})$, o *tempo de resposta* completo — a formulação original penalizava só o tempo de viagem, um bug de causa-raiz corrigido antes do primeiro resultado válido.

Treino: PPO/Stable-Baselines3, hiperparâmetros padrão ($\log 3 \times 10^{-4}$, $\gamma = 0,99$, 8 envs paralelos, seed 42), 500k timesteps (~ 2 h CPU). Defaults isolam o efeito da fonte de observação e do masking, não buscam o teto de desempenho do PPO.



Estatística: 1000 episódios pareados, Wilcoxon signed-rank, Cliff’s δ , IC 95% bootstrap. Pareamento é necessário porque a variância entre sementes já produz diferenças significativas em RL profundo.

Robustez: 6 regimes de carga (30s–10s), 500 episódios/ponto. **Por quê PPO e não SAC/DQN:** o experimento isola fonte de observação e masking sobre um único algoritmo, não faz benchmark de arquiteturas; PPO é o padrão de fato em SB3 com suporte nativo a masking (MaskablePPO), necessário para o teste causal a seguir.

LARS — Resultado: achado negativo e robustez

Política	Resp.	p95	Desbal.
Nearest-free	17,86 s	27,77 s	0,149
PPO (YOLO)	20,01 s	29,46 s	0,135
PPO (odom)	19,83 s	29,37 s	0,135

Carga moderada, 1000 ep. pareados, Wilcoxon $p < 0,001$. **O guloso vence**: tempo de resposta $\sim 12\%$ **pior** para o PPO. A proximidade entre PPO(YOLO) e PPO(odom) indica que o ruído do gêmeo digital é efeito de segunda ordem, não a causa.



O boxplot mostra p95/média comparável entre políticas ($\approx 1,47-1,56$): a desvantagem vem de deslocamento de toda a distribuição, não de cauda catastrófica. Sob carga, o gap encolhe de $+19,0\%$ para $+7,7\%$, mas o guloso permanece mais rápido em todo o intervalo testado.

LARS — Diagnóstico causal, limitações e fechamento

Três explicações investigadas: (1) restrição suave vs. rígida: o guloso nunca escolhe robô ocupado por construção; o PPO erra em 4,2% das decisões contra 0,3% do guloso ($\sim 13\times$ mais), o maior contribuinte isolado; (2) espaço de ação pequeno: com $N = 3$, no máximo três alternativas por decisão; (3) orçamento de treino: aprendizado claro, mas sem convergência.

Teste causal: PPO(YOLO, masked), ação restrita a robôs livres via *action masking* (MaskablePPO), mesmos hiperparâmetros e orçamento.


	Sem masking	Com masking
Taxa de ação inválida	4,2%	0,0%
Gap vs. guloso	$\sim 12\%$	$\sim 11\%$
Cliff's δ vs. guloso	0,703	0,636

Hipótese causal refutada: o masking zera a taxa de ação inválida, mas o gap melhora só ~ 1 ponto percentual. O peso volta para o espaço de ação pequeno e o orçamento de treino.

Limitações assumidas: (1) hiperparâmetros padrão do PPO, não o teto do RL para o problema; (2) $N = 3$, não extrapolar para frotas grandes; (3) sem validação em hardware físico; (4) 500k timesteps sem convergência. Todas são alvo direto de trabalho futuro. Revisão de literatura: 330 estudos triados (Scopus, IEEE, arXiv, ACM) $\rightarrow$ 117 aceitos / 213 rejeitados. Submissão: 06/08/2026, EasyChair; aceite previsto 15/09/2026. Título já declara o método (*Causal Diagnosis...*), não uma alegação de vitória do RL.

Por que um segundo paper: o LARS usa a posição do YOLO como estado observado, mas nunca pergunta o que fazer quando a detecção não está disponível. Em produção, um fallback discreto descarta informação (sem correção parcial, sem propagação formal de incerteza). A pergunta do LAFusion: como se comporta um EKF que funde as duas fontes probabilisticamente quando a taxa de detecção do YOLO é baixa?

LA Fusion — Arquitetura e pipeline



Módulos reais do código:

- ▶ `ekf_fusion_node.py`: nó ROS2 de produção. Um EKF independente por robô, predição via odometria, correção via detecção YOLO.
- ▶ `association.py`: gating de Mahalanobis compartilhado entre o EKF e o nó de avaliação offline.
- ▶ `projection.py`: projeção pixel↔mundo, com duas implementações confirmadas geometricamente equivalentes (heurística por FOV e via intrínsecos calibrados).

LA Fusion — Design do EKF

Estado: $x_k = [p_x, p_y, \theta]^\top$ por robô. A predição integra o *delta* de leituras consecutivas de odometria sobre o estado atual — não o valor absoluto, que descartaria correções visuais anteriores.

Hiperparâmetros e sua origem:

- ▶ $Q = \text{diag}(0,5, 0,5, 0,25)$ — calibrado empiricamente contra dados reais (varredura de 10^{-6} a $1,0$; ganho cresce monotonicamente até saturar em $Q \geq 0,5$).
- ▶ Teto de covariância $\text{clip}(P, -\infty, 0,05)$: *sem* ele, P crescia sem limite em intervalos longos sem correção (traço observado ≈ 85 contra esperado $\approx 0,5$), quebrando o gating de Mahalanobis ao alargar a região de aceitação até um robô “roubar” a detecção do vizinho.
- ▶ Limiar de gating $d^2 \leq 9,21$ — valor padrão do teste χ^2 com 2 graus de liberdade a 99% de confiança, não um número ajustado ad hoc.
- ▶ Atualização de P via **forma de Joseph** $(I - KH)P(I - KH)^\top + KRK^\top$, e gating com $S = P + R$ (não só P) — duas correções de rigor numérico aplicadas nesta sessão (17/08/2026), sem alterar nenhum resultado já publicado.

Por quê o teto de covariância existe: mantém a associação estável, não torna a estimativa de estado mais precisa durante o intervalo sem correção. É uma distinção central para a escolha do próximo bloco de slides.

LA Fusion — Testes e validação


Validação sintética (antes de qualquer dado real): Monte Carlo com 30 sementes, 2000 passos cada, contra trajetória sintética com verdade terrestre conhecida.

Estat.	Obtido	Esperado
NEES	2,955	3,0 (1,5%)
NIS	1,982	2,0 (0,9%)

Por quê validar sinteticamente antes do dado real: isola bugs de implementação de problemas de dado — um filtro mal calibrado contra dados sintéticos jamais seria confiável contra dados reais mais ruidosos.

Dados reais: 3 cenários gravados no Gazebo (parado, reto, curva/occlusão), 3 robôs, sincronização de timestamp verificada (nenhum gap >500ms).

Sobre benchmarks públicos: não avaliamos contra UTIAS MRCLAM ou S3E — ambos assumem sensor embarcado em cada robô (range-bearing ou LiDAR/estéreo/IMU onboard); nosso cenário usa câmera externa



NEES/NIS ao longo dos 2000 passos, com valor esperado teórico e faixa de confiança 95%: a tabela ao lado é só a média agregada das 30 sementes; esta figura confirma que a consistência do filtro se mantém estável do início ao fim da corrida, não só num regime transitório, antes de aplicá-lo aos dados reais.


LA Fusion — Resultado principal

Drift	Méd. EKF/Odom	Δ	RMSE EKF/Odom
Nenhum	0,036/0,000	N/A	0,052/0,000
Leve	0,053/0,050	-5,3%	0,068/0,066
Agressivo	0,128/0,168	+23,7%	0,163/0,195

Table: Erro de posição (m) nos instantes de correção YOLO, 3 cenários ($n = 1323$). Wilcoxon $p < 0,001$ sob drift agressivo.

Sob drift agressivo, o EKF reduz o erro médio em **+23,7%** frente à odometria pura.

Por quê o ganho é negativo sob drift leve (-5,3%): o erro de detecção visual ($\approx 3-6$ cm) ainda não é menor que o erro de odometria pouco corrompida nesse regime. Fundir as duas não ajuda, e pode piorar levemente. É comportamento esperado de um filtro corretamente calibrado, não uma falha.



Cenário 2 (preto) sob drift agressivo: EKF (azul) vs. odometria com drift (laranja, tracejada) vs. verdade terrestre (preto). A tabela reduz o ganho a um número agregado; aqui está o mecanismo — a odometria se afasta do caminho real enquanto o EKF permanece próximo, evidência qualitativa de que o filtro corrige o drift, não só que a métrica agregada melhorou.

LA Fusion — Achado central: o erro contínuo

Cenário	Cobertura	Média EKF/Odom	Δ	RMSE EKF/Odom	Δ RMSE
Parado	27,6%	0,212 / 0,177	-19,3%	0,246 / 0,205	-19,8%
Reto	11,3%	0,212 / 0,178	-18,8%	0,245 / 0,206	-19,2%
Curva/occlusão	0,0%	0,178 / 0,178	-0,0%	0,205 / 0,205	-0,0%
Agregado	—	0,200 / 0,178	-12,7%	0,233 / 0,205	-13,4%


Table: Erro medido a CADA leitura de odometria, não só nos instantes de correção ($n = 1607$, Wilcoxon $p < 0,001$).

Medido continuamente, o mesmo filtro é **12,7% pior** que odometria pura: sinal invertido em relação ao slide anterior. No cenário de 0% de cobertura, a mudança é exatamente 0,0%: sem correções, a predição do EKF degenera matematicamente para integração pura de delta-odometria, idêntica à baseline não fundida. É confirmação, não coincidência.

ATE vs. RPE (Sturm et al. 2012): o erro acima é ATE (erro absoluto por amostra). RPE (drift entre passos consecutivos) também piora, mas bem menos (-4,2% / -4,8% agregado) — a reversão vem sobretudo de erro *acumulando* sob correção esparsa, não de cada passo individual driftando muito mais que a odometria.

Isso não invalida a contribuição: reportar as duas métricas, em vez de só a favorável, é o ponto do trabalho, não uma admissão de fracasso.

LA Fusion — Por que o erro contínuo piora (fundamentação teórica)



A covariância satura no teto quase imediatamente após qualquer intervalo sem correção (Sinopoli et al. 2004: divergência de covariância abaixo de uma taxa crítica de observação; nosso cenário de 0% de cobertura está no caso-limite $p \rightarrow 0$). O teto evita crescimento ilimitado, mas capta a *estimativa de incerteza do próprio filtro*, não torna a estimativa de estado mais precisa: o filtro fica excessivamente confiante na predição só-odometria. Dissanayake et al. (2001) provam convergência do EKF-SLAM sob observação *densa*; nossa câmera viola essa premissa por construção (0–28% de cobertura).

Por que UKF/partículas/IMM não resolvem: um filtro de partículas degenera para propagação pura sem verossimilhança para reponderar; um UKF mira não-linearidade do modelo de observação, não a taxa de observação; um IMM ainda precisa de alguma observação para ponderar modos concorrentes. A causa raiz é a topologia do sensor (viewpoint único sujeito a oclusão), não a escolha do filtro.

LA Fusion — Estado atual: correção da calibração de câmera

Achado desta sessão (16/08): a calibração original, com os 4 intrínsecos livres (f_x, f_y, c_x, c_y), estava mal-condicionada — f_x 33% acima do valor geometricamente esperado, apesar de erro de reprojeção baixo (0,162px).

Causa raiz: com a câmera fixa olhando reto para baixo, o tabuleiro de calibração fica sempre fronto-paralelo ao sensor em todas as poses. É o caso degenerado clássico do método de Zhang (2000): sem variação de inclinação relativa entre sensor e alvo, f_x e a distância percebida ficam quase linearmente dependentes.

Correção aplicada: como a geometria da câmera simulada já era conhecida com precisão (altura e campo de visão nominais exatos), fixamos f_x, f_y, c_x, c_y no valor geométrico nominal e calibramos apenas a distorção — o remédio padrão quando os intrínsecos nominais já são confiáveis.

Resultado: a calibração corrigida reproduz a projeção heurística já usada em produção a menos de 0,001m de diferença, confirmando equivalência geométrica. **Nenhum resultado já publicado no paper muda:** a heurística de produção nunca esteve errada, só uma calibração alternativa em teste estava mal-condicionada.

Estado: paper com 8 páginas escritas (limite real do CFP é 12), prazo de submissão **04/09/2026**, formato Springer CCIS, revisão double-blind via Microsoft CMT.

Referências-chave e próximos passos

LARS — bibliografia essencial:

- ▶ Henderson et al. (2018): reprodutibilidade em RL profundo, motiva o teste pareado.
- ▶ Huang & Ontañón (2022): action masking produz gradiente válido; no nosso domínio elimina a violação sem fechar o gap.
- ▶ Agrawal et al. (2023, RTAW), Paul et al. (2022, Capsule Attention): arquiteturas atencionais como direção futura.

Próximos passos: aguardar aceite (15/09/2026); espaço de ação e orçamento de treino maiores; formulação Dec-POMDP (CTDE).

LA Fusion — bibliografia essencial:

- ▶ Sinopoli (2004), Bailey & Durrant-Whyte (2006), Dissanayake et al. (2001): fundamentação teórica clássica do achado central (erro contínuo, modelo EKF, convergência sob observação densa).
- ▶ Khosravi et al. (2026): localização cooperativa com fusão assíncrona, cenário mais próximo do nosso.
- ▶ Ahmed & Frémont (2026): rastreamento multi-robô descentralizado, mesma classe de problema.
- ▶ Dobrynin & Garcia (2025): testbed TurtleBot3 com EKF distribuído.

Próximos passos: submissão no CMT até 04/09/2026; Q adaptativo por tempo desde a última correção; Jacobiano completo na projeção; associação robusta (Hungarian/JPDA); LiDAR como terceira fonte.

Conclusão — LARS: resultado negativo testado e explicado causalmente; o *action masking* refuta a explicação mais plausível a priori, redirecionando o diagnóstico para o espaço de ação pequeno e o orçamento de treino.

LA Fusion: ganho real nos instantes de correção (+23,7%), mas mensuravelmente pior que odometria pura avaliado continuamente (−12,7%), reversão explicada pela teoria estabelecida de filtragem sob observação intermitente, não uma falha de implementação. Os dois trabalhos compartilham o mesmo padrão: reportar o resultado completo, favorável ou não, e fundamentá-lo.