

CERISE — Dois Trabalhos, Uma Base Comum

LARS 2026 (alocação de tarefas via RL) e LAFusion 2026 (fusão sensorial via EKF)

Yan Santos Leite

Orientador: Prof. Alisson Assis Cardoso

Escola de Engenharia Elétrica, Mecânica e de Computação (EMC) — UFG
Fundação de Amparo à Pesquisa do Estado de Goiás (FAPEG)

16 de agosto de 2026

Roteiro

Esta apresentação cobre a trajetória completa de dois trabalhos que compartilham a mesma base de código e a mesma plataforma física (três TurtleBot3 no CERISE), mas respondem a perguntas de pesquisa diferentes.

1. **LARS 2026** — da concepção à submissão (06/08): um agente de RL supera a heurística gulosa na alocação de tarefas? Arquitetura, resultado, diagnóstico causal, fechamento.
2. **LA Fusion 2026** — da concepção ao estado atual (16/08): um EKF de fusão sensorial melhora a localização sob observação visual esparsa? Arquitetura, validação, resultado, achado central.
3. **Conclusão** — o que cada trabalho contribui e os próximos passos concretos de cada um.

Os dois papers reaproveitam a mesma bateria de testes estatísticos (`stats_tests.py`: Wilcoxon signed-rank, Cliff's δ , IC bootstrap) — não são iniciativas isoladas, mas duas perguntas feitas sobre a mesma infraestrutura experimental.

Visão geral dos dois trabalhos

	LARS 2026	LAFusion 2026
Pergunta	RL supera a heurística gulosa na alocação de tarefas?	EKF melhora a localização sob cobertura visual esparsa?
Método	PPO (Stable-Baselines3)	Extended Kalman Filter por robô
Plataforma	3 TurtleBot3, ROS2/Gazebo	3 TurtleBot3, ROS2/Gazebo
Estado	Submetido no EasyChair em 06/08	8 páginas prontas, prazo 04/09

Os dois trabalhos compartilham a câmera overhead + detector YOLOv8n como fonte de posição, mas usam esse dado de formas opostas: o LARS o consome diretamente como estado observado pelo agente; o LAFusion pergunta o que fazer quando esse dado *nem sempre está disponível*.

LARS — Motivação

O problema. Alocação de tarefas multi-robô (MRTA) é resolvida na prática por heurísticas gulosas: atribuem a tarefa ao robô livre mais próximo, sem olhar para demandas futuras. São rápidas e respeitam restrições operacionais por construção (nunca escolhem um robô ocupado), mas são míopes — não veem que o robô mais próximo agora pode ser o mais útil daqui a pouco.

Por que RL. Uma política aprendida pode, em princípio, trocar uma atribuição localmente subótima por um resultado melhor no conjunto do episódio — é exatamente essa miopia que o RL promete corrigir.

Hipótese testada. Uma política PPO com antecipação de duas demandas futuras supera a heurística *nearest-free* em tempo de resposta.

LARS — Arquitetura e pipeline

Pipeline conceitual:


Câmera overhead → YOLOv8n → /robot_detections → AllocationEnv → Política
PPO → Nav2 → TurtleBot3

Módulos reais do código:


- ▶ `yolo_detector.py` — nó ROS2 que publica a posição estimada de cada robô a partir da câmera overhead.
- ▶ `rl/allocation_env.py` — ambiente Gymnasium *analítico* (sem ROS/Gazebo): cada `step()` é aritmética pura sobre um modelo de navegação, o que permite treinar 500 mil timesteps em minutos em vez de dias.
- ▶ `rl_task_allocator.py` — nó ROS2 de inferência, que carrega a política treinada no ambiente analítico e a aplica sobre posições reais do YOLO.
- ▶ `task_allocator.py` — a heurística *nearest-free*, usada como baseline.

O treino roda inteiramente no ambiente analítico; o Gazebo é reservado para validação final de ponta a ponta, não para treino — treinar direto no simulador físico custaria ordens de magnitude mais tempo pelo mesmo motivo que qualquer simulação física é mais lenta que aritmética vetorizada

LARS — Detecção YOLO: verdade vs. predição



Verdade terrestre




Predição do detector

Anotação de verdade terrestre vs. predição do detector, mesma cena do conjunto de validação, um a três robôs simultaneamente visíveis.

Por que esta figura importa: o $mAP@0,5=0,995$ e o erro de 4,7 cm do próximo slide são médias agregadas — não mostram *como* o detector erra. Esta comparação qualitativa é a evidência de que o erro reportado é bem comportado (caixa acompanha o robô de forma consistente, mesmo com múltiplos robôs próximos) e não um artefato de outliers escondidos pela média.

LARS — Gêmeo digital: evolução da precisão



Modelo: YOLOv8n, 375 frames anotados manualmente.

mAP@0.5	0,995
Erro estático (8 poses)	1,24 cm
Erro dinâmico (rastreo)	4,7 cm
Detecções <15 cm	100%

O salto de 1,24 cm para 4,7 cm entre o benchmark estático e o rastreamento contínuo é esperado — motion blur e latência de detecção-para-pose em movimento, não uma limitação do detector. É o erro de 4,7 cm, não o estático, que alimenta todos os experimentos seguintes.

LARS — Formulação do MDP

Estado (21 dimensões): para $N = 3$ robôs, $3N + 4 + 4 \times 2 = 21$ — posição (x, y) e tempo até ficar livre de cada robô, origem/destino da demanda atual, e origem/destino das **2 próximas demandas** já visíveis na fila.


Por quê a antecipação: sem ver as próximas demandas, a política não tem como decidir "segurar" um robô livre para uma tarefa melhor que está a caminho — é essa antecipação, e só ela, que poderia justificar vencer a heurística míope.

Ação: escolha discreta de qual dos N robôs atende a demanda atual.

Recompensa: $r = -(t_{espera} + t_{viagem})$ — o *tempo de resposta* completo, não só o tempo de viagem.

Por quê essa correção importa: a formulação original penalizava só o tempo de viagem até a demanda, ignorando quanto tempo o robô escolhido ainda levaria para ficar livre. Sob essa formulação anterior, um robô ocupado-mas-próximo podia parecer tão bom quanto um livre-mas-distante — a fila nunca era penalizada, e a política enviesava para robôs livres mesmo quando distantes. Foi um bug de causa-raiz corrigido antes do primeiro resultado válido, não um ajuste de sintonia fina.

LARS — Curva de aprendizado



Recompensa média por episódio ao longo de 500 mil timesteps, PPO(YOLO) e PPO(odom), com a linha de referência do guloso ($-16,7$).

Por que esta figura importa: confirma, antes de qualquer teste estatístico, que o PPO de fato aprendeu ($\sim -21 \rightarrow \sim -17,7$) — descarta a hipótese trivial de que o resultado negativo dos slides seguintes se deve a um agente que não treinou. Mostra também que **nenhuma das duas variantes cruza a linha do guloso**, e que PPO(odom) converge ligeiramente mais rápido que PPO(YOLO) — evidência direta de que o ruído do gêmeo digital (4,7 cm) é efeito de segunda ordem, não a causa do gap.

LARS — Testes e protocolo experimental

Treino: PPO via Stable-Baselines3, hiperparâmetros *padrão da biblioteca* (taxa de aprendizado 3×10^{-4} , $\gamma = 0,99$, 8 ambientes paralelos, seed 42), 500 mil timesteps (~ 2 h CPU).

Por quê hiperparâmetros padrão: o objetivo do experimento é isolar o efeito da fonte de observação (YOLO vs. odometria) e do *action masking*, não encontrar o teto de desempenho do PPO por meio de tuning — usar os defaults deixa claro que o resultado concerne ao PPO como comumente aplicado, e essa é uma limitação assumida explicitamente no paper, não escondida.

Comparação estatística: 1000 episódios pareados (mesma semente e sequência de demandas entre políticas), **Wilcoxon signed-rank** para significância, **Cliff's δ** para tamanho de efeito, IC 95% bootstrap.

Por quê pareamento: a variância entre sementes aleatórias, isolada, já produz diferenças estatisticamente significativas em RL profundo — comparar médias sem teste pareado mediria ruído de treino, não a diferença real entre políticas.

Robustez sob carga: varredura de 6 regimes de intervalo entre demandas, de 30s a 10s, 500 episódios por ponto.

LARS — Primeiro resultado: achado negativo


Política	Resp. média	p95	Custo/ep.	Desbal.
Nearest-free	17,86 s	27,77 s	357,18 s	0,149
PPO (YOLO)	20,01 s	29,46 s	400,20 s	0,135
PPO (odom)	19,83 s	29,37 s	396,69 s	0,135

Table: Carga moderada (12s entre demandas), 1000 episódios pareados. Wilcoxon $p < 0,001$ em ambas as comparações contra nearest-free.

Contra a hipótese, **o guloso vence** — tempo de resposta médio cerca de **12% pior** para o PPO. A diferença entre PPO(YOLO) e PPO(odom) é pequena frente à distância de ambos ao guloso: o ruído de 4,7 cm do gêmeo digital é um efeito de segunda ordem, não a causa do resultado.


Enquadramento: um resultado negativo bem caracterizado — testado e explicado — é mais informativo do que uma alegação positiva não testada. É essa caracterização, não a vitória do método proposto, que constitui a contribuição científica aqui.

LARS — Distribuição completa do tempo de resposta



Por que esta figura importa: a tabela anterior mostra só médias e p95 — não revela **onde** na distribuição o PPO perde. Este boxplot mostra que a razão p95/média é comparável entre políticas ($\approx 1,47$ – $1,56$) e, de fato, ligeiramente menor para o PPO. Isso descarta uma explicação alternativa plausível (PPO pior só por causa de uma cauda de episódios catastróficos) — a desvantagem vem de um deslocamento de toda a distribuição de tempo de resposta, não de eventos raros.

LARS — Robustez sob carga



Tempo de resposta em função do intervalo entre demandas (30s a 10s), nearest-free e PPO(YOLO): a desvantagem do PPO **encolhe** de +19,0% (carga baixa) para +7,7% (carga alta), embora o guloso permaneça mais rápido em todo o intervalo testado.

Por que esta figura importa: responde a "o resultado é só válido na carga testada?" — o custo do PPO fica quase plano (397–400s) entre regimes, enquanto o do guloso cresce sob carga alta. Sustenta a leitura de que, se existe um ponto de cruzamento onde o PPO supera o guloso, ele está fora do intervalo testado (cargas mais altas ou frotas maiores), não dentro dele.

LARS — Diagnóstico causal: por que o PPO perde?

Três explicações foram investigadas antes de qualquer teste:

- ▶ **Restrição suave vs. rígida.** O guloso nunca escolhe um robô ocupado — a restrição está embutida no próprio algoritmo. O PPO só aprende a evitar isso indiretamente via penalidade no reward, e ainda assim erra em **4,2%** das decisões contra **0,3%** do guloso ($\sim 13\times$ mais) — o maior contribuinte isolado encontrado.
- ▶ **Espaço de ação pequeno.** Com $N = 3$, cada decisão tem no máximo três alternativas, limitando qualquer vantagem que a antecipação poderia explorar.
- ▶ **Orçamento de treino.** 500 mil passos mostraram aprendizado claro, mas não convergência — embora o custo do PPO fique quase constante entre regimes de carga (397–400s) enquanto o do guloso cresce sob carga alta, sugerindo que o platô não é puramente um artefato de orçamento.

Por quê testar a restrição suave primeiro: era a explicação mais barata de testar causalmente (não exige mudar arquitetura nem orçamento) e a mais plausível a priori, dado o fator de $13\times$ no `invalid_rate`.

LARS — Teste causal: *action masking*

O teste. Treinamos PPO(YOLO, masked): idêntico ao PPO(YOLO), mas a distribuição de ação é restrita a cada passo aos robôs livres — via *action masking* (MaskablePPO, sb3-contrib), mesmos hiperparâmetros e orçamento de treino.

	Sem masking	Com masking
Taxa de ação inválida	4,2%	0,0%
Gap de tempo de resposta vs. guloso	~12%	~11%
Cliff's δ vs. guloso	0,703	0,636

Resultado: a hipótese causal é refutada. O masking cumpre seu objetivo estrutural — zera a taxa de ação inválida — mas o gap de tempo de resposta melhora só ~1 ponto percentual. A restrição suave não era a causa dominante do gap.

Implicação: o peso volta para o espaço de ação pequeno e o orçamento de treino. Uma hipótese adicional emerge: ao impedir a política de sequer considerar robôs ocupados, o masking também remove o sinal de aprendizado sobre a consequência dessa escolha — pode reduzir a diversidade de exploração sem trazer, em troca, vantagem de antecipação.

LARS — Limitações assumidas explicitamente

O resultado é delimitado por quatro escolhas, reconhecidas no próprio paper:

1. **Hiperparâmetros padrão do PPO** — o resultado concerne ao PPO como comumente aplicado, não ao teto do RL para este problema; uma política ajustada pode fechar o gap.
2. $N = 3$ **robôs** — espaço de ação pequeno, e o próprio diagnóstico aponta isso como fator dominante; o achado não deve ser extrapolado para frotas grandes.
3. **Sem validação em hardware físico** — a política treina no ambiente analítico e é validada de ponta a ponta no Gazebo, mas a transferência sim-to-real permanece não testada.
4. **500 mil timesteps sem convergência** — houve aprendizado, não convergência.

Cada uma dessas quatro limitações é um alvo direto de trabalho futuro — não pontos cegos descobertos depois, mas escopo delimitado desde a escrita do paper.

LARS — Fechamento: revisão de literatura e submissão

Por que uma revisão sistemática: para posicionar corretamente um resultado negativo contra o estado da arte, era preciso primeiro mapear esse estado da arte com rigor — sem isso, "o RL não venceu" não se sustenta como contribuição, pode só parecer uma tentativa malfeita.

Revisão de literatura: 330 estudos triados (Scopus, IEEE, arXiv, ACM) → **117 aceitos / 213 rejeitados**, 122 com extração de dados completa.

Submissão: 06/08/2026, 03:17 UTC, EasyChair (LARS 2026), dentro do prazo. Notificação de aceite prevista para **15/09/2026**.

Título final: *"Causal Diagnosis of Reinforcement Learning Performance in Vision-Based Multi-Robot Task Allocation with a Digital Twin"* — o título já declara o método (diagnóstico causal), não uma alegação de vitória do RL.

Transição: por que um segundo paper?

O LARS usa a posição do YOLO como estado observado pelo agente — mas nunca pergunta *o que fazer quando essa detecção não está disponível*. Em produção, isso é tratado por um **fallback discreto**: confiar na detecção quando associada, na odometria caso contrário.

O gap técnico: um fallback discreto descarta informação — não há correção parcial de detecções de baixa confiança, não há propagação formal de incerteza, e não há comportamento principiado durante longos períodos sem detecção visual.

A pergunta do LAFusion: um Extended Kalman Filter, que funde as duas fontes de forma probabilística em vez de escolher uma ou outra, melhora a localização sob a cobertura visual esparsa que uma câmera fixa realmente produz?

LA Fusion — Arquitetura e pipeline

Pipeline conceitual:

Câmera overhead fixa → YOLOv8n → Associação (Mahalanobis) → EKF por robô → pose fundida

Módulos reais do código:

- ▶ `ekf_fusion_node.py` — nó ROS2 de produção: um EKF independente por robô, predição via odometria, correção via detecção YOLO.
- ▶ `association.py` — gating de Mahalanobis compartilhado entre o EKF e o nó de avaliação offline.
- ▶ `projection.py` — projeção pixel↔mundo, com duas implementações confirmadas geometricamente equivalentes (heurística por FOV e via intrínsecos calibrados).

Por que EKF, e não UKF ou filtro de partículas: o modelo de observação da câmera é quase linear (projeção pinhole numa cena essencialmente planar) — o ganho de um UKF, que mira não-linearidade do modelo de observação, seria marginal aqui. O problema central deste trabalho é a *taxa* de observação, não a forma do modelo, e nenhuma dessas alternativas resolve isso (detalhado dois slides à frente).

LA Fusion — Design do EKF

Estado: $x_k = [p_x, p_y, \theta]^T$ por robô. A predição integra o *delta* de leituras consecutivas de odometria sobre o estado atual — não o valor absoluto, que descartaria correções visuais anteriores.

Hiperparâmetros e sua origem:

- ▶ $Q = \text{diag}(0,5, 0,5, 0,25)$ — calibrado empiricamente contra dados reais (varredura de 10^{-6} a 1,0; ganho cresce monotonicamente até saturar em $Q \geq 0,5$).
- ▶ Teto de covariância $\text{clip}(P, -\infty, 0,05)$ — *sem* ele, P crescia sem limite em intervalos longos sem correção (traço observado ≈ 85 contra esperado $\approx 0,5$), quebrando o gating de Mahalanobis ao alargar a região de aceitação até um robô "roubar" a detecção do vizinho.
- ▶ Limiar de gating $d^2 \leq 9,21$ — valor padrão do teste χ^2 com 2 graus de liberdade a 99% de confiança, não um número ajustado ad hoc.

Por quê o teto de covariância existe: mantém a associação estável, não torna a estimativa de estado mais precisa durante o intervalo sem correção — distinção central para o achado do próximo bloco de slides.

Por quê Q fixo e não adaptativo desde o início: um teto fixo é a versão mais simples a validar primeiro; Q escalado pelo tempo desde a última correção é mais correto teoricamente, mas adiciona um hiperparâmetro a calibrar — por isso entra como próximo passo, não como ponto de partida.

LA Fusion — Testes e validação

Validação sintética (antes de qualquer dado real): Monte Carlo com 30 sementes, 2000 passos cada, contra trajetória sintética com verdade terrestre conhecida.


Estatística	Obtido	Esperado
NEES	2,955	3,0 (erro 1,5%)
NIS	1,982	2,0 (erro 0,9%)

Por quê validar sinteticamente antes do dado real: isola bugs de implementação de problemas de dado — um filtro mal calibrado contra dados sintéticos jamais seria confiável contra dados reais mais ruidosos.

Dados reais: 3 cenários gravados no Gazebo (parado, reto, curva/occlusão), 3 robôs, sincronização de timestamp verificada (nenhum gap >500ms).

Sobre benchmarks públicos: não avaliamos contra UTIAS MRCLAM ou S3E — ambos assumem sensor embarcado em cada robô (range-bearing ou LiDAR/estéreo/IMU onboard); nosso cenário usa câmera externa fixa, mais próximo de um ambiente instrumentado do que de SLAM cooperativo. Não há, até onde sabemos, dataset público que combine câmera externa fixa, YOLO e múltiplos robôs terrestres como alvos — o que motiva o dataset próprio liberado com este trabalho.

LA Fusion — Consistência do filtro ao longo do tempo



NEES e NIS ao longo dos 2000 passos da validação Monte Carlo (30 sementes), com valores esperados teóricos (3,0 e 2,0) e faixa de confiança 95%.

Por que esta figura importa: a tabela do slide anterior mostra só a média agregada das 30 sementes — não mostra **se** o filtro permanece consistente ao longo de toda a trajetória ou só na média. Esta figura confirma que NEES/NIS oscilam em torno do valor esperado de forma estável do início ao fim da corrida, não só nos primeiros ou últimos passos — evidência de que a calibração do filtro (Q , R) não depende de um regime transitório específico antes de ser aplicada aos dados reais.

LA Fusion — Resultado principal


Regime de drift	Média EKF/Odom	Δ média	RMSE EKF/Odom	Δ RMSE
Nenhum (odom = GT)	0,036 / 0,000	N/A	0,052 / 0,000	N/A
Leve	0,053 / 0,050	-5,3%	0,068 / 0,066	-2,1%
Agressivo	0,128 / 0,168	+23,7%	0,163 / 0,195	+16,7%

Table: Erro de posição (m) nos instantes de correção YOLO, agregado em 3 cenários ($n = 1323$). Wilcoxon $p < 0,001$ sob drift agressivo.

Sob drift agressivo, o EKF reduz o erro médio em **+23,7%** frente à odometria pura.

Por quê o ganho é negativo sob drift leve (-5,3%): o erro de detecção visual ($\approx 3-6$ cm) ainda não é menor que o erro de odometria pouco corrompida nesse regime — fundir as duas não ajuda, e pode piorar levemente. É comportamento esperado de um filtro corretamente calibrado, não uma falha.

LA Fusion — Trajetória estimada



Cenário 2 (movimento reto) sob drift agressivo: EKF (azul) vs. odometria bruta com drift (laranja, tracejada) vs. verdade terrestre (preto).

Por que esta figura importa: a tabela anterior reduz o ganho de +23,7% a um único número agregado — esta figura mostra **o mecanismo** por trás dele: a odometria bruta visivelmente se afasta do caminho reto real, enquanto a estimativa do EKF permanece próxima da trajetória verdadeira. É a evidência qualitativa de que o filtro está corrigindo o drift, não só de que uma métrica agregada melhorou.

LA Fusion — Achado central: o erro contínuo


Cenário	Cobertura	Média EKF/Odom	Δ	RMSE EKF/Odom	Δ RMSE
Parado	27,6%	0,212 / 0,177	-19,3%	0,246 / 0,205	-19,8%
Reto	11,3%	0,212 / 0,178	-18,8%	0,245 / 0,206	-19,2%
Curva/occlusão	0,0%	0,178 / 0,178	-0,0%	0,205 / 0,205	-0,0%
Agregado	—	0,200 / 0,178	-12,7%	0,233 / 0,205	-13,4%

Table: Erro medido a CADA leitura de odometria, não só nos instantes de correção ($n = 1607$, Wilcoxon $p < 0,001$).

Medido continuamente, o mesmo filtro é **12,7% pior** que odometria pura — sinal invertido em relação ao slide anterior. No cenário de 0% de cobertura, a mudança é exatamente 0,0%: sem correções, a predição do EKF degenera matematicamente para integração pura de delta-odometria, idêntica à baseline não fundida — confirmação, não coincidência.

Isso não invalida a contribuição: reportar as duas métricas — em vez de só a favorável — é o ponto do trabalho, não uma admissão de fracasso.

LA Fusion — Por que o erro contínuo piora (fundamentação teórica)



A covariância satura no teto quase imediatamente após qualquer intervalo sem correção (Sinopoli et al. 2004: divergência de covariância abaixo de uma taxa crítica de observação — nosso cenário de 0% de cobertura está no caso-limite $p \rightarrow 0$). O teto evita crescimento ilimitado, mas capta a *estimativa de incerteza do próprio filtro*, não torna a estimativa de estado mais precisa — o filtro fica excessivamente confiante na predição só-odometria. Dissanayake et al. (2001) provam convergência do EKF-SLAM sob observação *densa*; nossa câmera viola essa premissa por construção (0–28% de cobertura).

Por que UKF/partículas/IMM não resolvem: um filtro de partículas degenera para propagação pura sem verossimilhança para reponderar; um UKF mira não-linearidade do modelo de observação, não a taxa de observação; um IMM ainda precisa de alguma observação para ponderar modos concorrentes. A causa raiz é a topologia do sensor (viewpoint único sujeito a oclusão), não a escolha do filtro.

LA Fusion — Estado atual: correção da calibração de câmera

Achado desta sessão (16/08): a calibração original, com os 4 intrínsecos livres (f_x, f_y, c_x, c_y), estava mal-condicionada — f_x 33% acima do valor geometricamente esperado, apesar de erro de reprojeção baixo (0,162px).

Causa raiz: com a câmera fixa olhando reto para baixo, o tabuleiro de calibração fica sempre fronto-paralelo ao sensor em todas as poses — o caso degenerado clássico do método de Zhang (2000): sem variação de inclinação relativa entre sensor e alvo, f_x e a distância percebida ficam quase linearmente dependentes.

Correção aplicada: como a geometria da câmera simulada já era conhecida com precisão (altura e campo de visão nominais exatos), fixamos f_x, f_y, c_x, c_y no valor geométrico nominal e calibramos apenas a distorção — o remédio padrão quando os intrínsecos nominais já são confiáveis.

Resultado: a calibração corrigida reproduz a projeção heurística já usada em produção a menos de 0,001m de diferença — confirmando equivalência geométrica. **Nenhum resultado já publicado no paper muda:** a heurística de produção nunca esteve errada, só uma calibração alternativa em teste estava mal-condicionada.

Estado: paper com 8 páginas escritas (limite real do CFP é 12), prazo de submissão **04/09/2026**, formato Springer CCIS, revisão double-blind via Microsoft CMT.

Referências-chave e próximos passos

LARS — bibliografia essencial:

- ▶ Henderson et al. (2018) — reprodutibilidade em RL profundo, motiva o teste pareado usado aqui.
- ▶ Huang & Ontañón (2022) — action masking produz gradiente de política válido; nosso domínio difere do deles porque o masking elimina a violação sem fechar o gap.
- ▶ Agrawal et al. (2023, RTAW) e Paul et al. (2022, Capsule Attention) — arquiteturas atencionais como direção futura.

Próximos passos: aguardar notificação de aceite (15/09/2026); espaço de ação e orçamento de treino maiores, guiados pelo diagnóstico causal; formulação Dec-POMDP (CTDE) como trabalho futuro.

LA Fusion — bibliografia essencial:

- ▶ Sinopoli et al. (2004) e Censi (2009) — fundamentam por que o erro contínuo piora sob observação intermitente.
- ▶ Bailey & Durrant-Whyte (2006) — modelo EKF padrão que o filtro segue.
- ▶ Dissanayake et al. (2001) — convergência sob observação densa, premissa violada por construção aqui.

Próximos passos: submissão no CMT até 04/09/2026; Q adaptativo por tempo desde a última correção; LiDAR como terceira fonte de fusão (já publicado, não usado).

Conclusão

LARS 2026: um resultado negativo, testado e explicado causalmente — o PPO não supera a heurística gulosa neste cenário, e o *action masking* refuta a explicação mais plausível a priori, redirecionando o diagnóstico para o espaço de ação pequeno e o orçamento de treino. A contribuição é a caracterização causal, não uma vitória do método proposto.

LA Fusion 2026: um EKF de fusão sensorial entrega ganho real nos instantes de correção (+23,7%), mas é mensuravelmente pior que odometria pura quando avaliado continuamente (−12,7%) sob a cobertura visual esparsa que uma câmera fixa realmente produz — reversão explicada pela teoria estabelecida de filtragem de Kalman sob observação intermitente, não uma falha de implementação.

Os dois trabalhos compartilham o mesmo padrão: reportar o resultado completo, favorável ou não, e fundamentá-lo — não filtrar para a métrica mais favorável.