

CERISE — Dois Trabalhos, Uma Base Comum

LARS 2026 (alocação de tarefas via RL) e LAFusion 2026 (fusão sensorial via EKF)

Yan Santos Leite

Orientador: Prof. Alisson Assis Cardoso

Escola de Engenharia Elétrica, Mecânica e de Computação (EMC) — UFG
Fundação de Amparo à Pesquisa do Estado de Goiás (FAPEG)

28 de agosto de 2026

Roteiro e visão geral dos dois trabalhos

Dois trabalhos que compartilham a base de código e a plataforma física (três TurtleBot3 no CERISE), mas respondem perguntas diferentes. O LARS já foi submetido em 06/08; esta apresentação foca no LAFusion, a sete dias do prazo, e fecha com a conclusão e os próximos passos dos dois.

	LARS 2026	LAFusion 2026
Pergunta	RL supera a heurística gulosa na alocação de tarefas?	Como o EKF se comporta quando a taxa de detecção do YOLO é baixa?
Método	PPO (Stable-Baselines3)	Extended Kalman Filter por robô
Plataforma	3 TurtleBot3, ROS2/Gazebo	3 TurtleBot3, ROS2/Gazebo
Estado	Submetido no EasyChair em 06/08	Prazo de submissão 04/09

A mesma câmera overhead com YOLOv8n alimenta os dois trabalhos. O LARS trata a posição detectada como dado disponível, no estado do agente. O LAFusion assume o contrário: a detecção às vezes falta, e resolver essa lacuna é o problema central.

Tese, argumentação e contribuições


Tese central. Nos dois casos, o resultado inesperado vem acompanhado da explicação de por que aconteceu.

Como a tese se sustenta:

- ▶ **LARS:** testa a hipótese de que RL supera a heurística, encontra o oposto, e refuta a explicação mais plausível a priori com um experimento causal (*action masking*).
- ▶ **LAFusion:** o EKF melhora a posição no instante da correção (+23,7%), mas piora quando medido de forma contínua (−12,7%). Isso é o comportamento esperado quando o filtro passa muito tempo sem correção, o que explica a piora.

Contribuições: (1) um gêmeo digital câmera+YOLO validado ($mAP@0,5=0,995$, erro de 4,7 cm), base comum aos dois trabalhos; (2) a causa de o PPO perder para a heurística na alocação de tarefas entre 3 robôs: o espaço de ação pequeno; (3) uma avaliação do EKF sob baixa taxa de detecção do YOLO em duas frentes: +23,7% de ganho nos instantes de correção e −12,7% de erro medido continuamente.

LA Fusion — Arquitetura e pipeline



`yolo_detector.py` já converte pixel→mundo (via `projection.py`) antes de publicar `/robot_detections`. A seta tracejada mostra que o EKF publica pose a cada leitura de odometria (predição), não só após uma correção YOLO. `association.py` e `ekf_core.py` não são nós ROS2 à parte: são módulos importados e chamados de dentro do próprio `ekf_fusion_node.py` (setas pontilhadas). `association.py` faz o gating de Mahalanobis por vizinho mais próximo (não JPDA nem Hungarian), suficiente para $N = 3$ mas com risco de troca de identidade se dois robôs ficarem muito próximos. `ekf_core.py` concentra a correção (forma de Joseph), reaproveitada por produção, avaliação offline e validação sintética.

Por que EKF, e não UKF ou filtro de partículas: o modelo de observação da câmera é quase linear (projeção pinhole numa cena planar), então o ganho de um UKF seria marginal. O problema central aqui é a *taxa* de observação, não a forma do modelo.

LA Fusion — Design do EKF e validação

Estado: $x_k = [p_x, p_y, \theta]^\top$ por robô. A predição integra o *delta* de odometria, não o valor absoluto, preservando correções visuais anteriores.

Hiperparâmetros e sua origem:

- ▶ $Q = \text{diag}(0,5, 0,5, 0,25)$: calibrado contra dados reais, ganho satura em $Q \geq 0,5$.
- ▶ Teto $\text{clip}(P, -\infty, 0,05)$: sem ele P cresce sem limite (traço ≈ 85) e quebra o gating, deixando um robô “roubar” a detecção do vizinho.
- ▶ Gating $d^2 \leq 9,21$: padrão do χ^2 com 2 g.l. a 99%.
- ▶ Forma de Joseph e gating com $S = P + R$: rigor numérico, reproduzem os resultados publicados.

Por que o teto existe: mantém a associação estável, mas o estado segue impreciso sem correção. Um *fading factor* (AFKF), teoricamente melhor, foi testado e perde: o ganho sob drift agressivo cai de +23,7% para -16,5%.

Validação sintética, antes de qualquer dado real: Monte Carlo, 30 sementes, 2000 passos, contra verdade terrestre conhecida.

Estat.	Obtido	Esperado
NEES	2,955	3,0 (1,5%)
NIS	1,982	2,0 (0,9%)

Isso isola bugs de implementação de problemas de dado: um filtro inconsistente contra dados sintéticos jamais seria confiável contra dados reais.

Dados reais: 3 cenários no Gazebo (parado, reto, curva/occlusão), 3 robôs, sincronização verificada.

Regressão produção vs. avaliação: `predict()` não é compartilhada entre os dois (modelos de movimento diferentes), então um teste compara numericamente as duas implementações a cada passo, para os mesmos dados de entrada, e falha se divergirem.

O mesmo filtro ganha +23,7% na correção e perde -12,7% medido continuamente

(a) Nos instantes de correção YOLO

Drift	EKF/Odom	Δ	Δ RMSE
Nenhum	0,036/0,000	N/A	N/A
Leve	0,053/0,050	-5,3%	-2,1%
Agressivo	0,128/0,168	+23,7%	+16,7%

$n = 1323$, Wilcoxon $p < 0,001$ sob drift agressivo.

Por que o ganho é negativo sob drift leve: o erro de detecção visual ($\approx 3-6$ cm) ainda supera o de uma odometria pouco corrompida, então fundir as duas fontes piora o resultado. É o comportamento esperado de um filtro bem calibrado.

ATE vs. RPE (Sturm et al. 2012): o erro em (b) é ATE, absoluto por amostra; o RPE (drift entre passos consecutivos) piora bem menos (-4,2%), então a reversão vem de erro *acumulando* sob correção esparsa.

Fundamentação: Sinopoli et al. (2004) mostram que a covariância diverge abaixo de uma taxa crítica de observação, e 0% de cobertura é o caso-limite $p \rightarrow 0$; o teto evita o crescimento ilimitado, mas limita só a *incerteza estimada*, deixando o filtro confiante demais na predição só-odometria. Dissanayake et al. (2001) provam convergência do EKF-SLAM sob observação *densa*, premissa violada aqui por construção. UKF, partículas e IMM não resolvem: a causa raiz é a topologia do sensor, não a escolha do filtro.

(b) A cada leitura de odometria

Cenário	Cobert.	EKF/Odom	Δ
Parado	27,6%	0,212/0,177	-19,3%
Reto	11,3%	0,212/0,178	-18,8%
Curva/ocl.	0,0%	0,178/0,178	-0,0%
Agregado	—	0,200/0,178	-12,7%

$n = 1607$, Wilcoxon $p < 0,001$.

Com 0% de cobertura a mudança é exatamente 0,0%: sem correções o EKF degenera para integração pura de delta-odometria. A coincidência exata confirma o mecanismo.

Referências-chave e próximos passos

LARS — bibliografia essencial:

- ▶ Henderson et al. (2018): reprodutibilidade em RL profundo, motiva o teste pareado.
- ▶ Huang & Ontañón (2022): action masking produz gradiente válido; no nosso domínio elimina a violação sem fechar o gap.
- ▶ Agrawal et al. (2023, RTAW), Paul et al. (2022, Capsule Attention): arquiteturas atencionais como direção futura.

Próximos passos: aguardar aceite (15/09/2026); espaço de ação e orçamento de treino maiores; formulação Dec-POMDP (CTDE).

LAFusion — bibliografia essencial:

- ▶ Sinopoli (2004), Bailey & Durrant-Whyte (2006), Dissanayake et al. (2001): fundamentação teórica clássica do achado central (erro contínuo, modelo EKF, convergência sob observação densa).
- ▶ Khosravi et al. (2026): localização cooperativa com fusão assíncrona, cenário mais próximo do nosso.
- ▶ Ahmed & Frémont (2026): rastreo multi-robô descentralizado, mesma classe de problema.
- ▶ Dobrynin & Garcia (2025): testbed TurtleBot3 com EKF distribuído.

Próximos passos: submissão no CMT até 04/09/2026; Q adaptativo por tempo desde a última correção; Jacobiano completo na projeção; associação robusta (Hungarian/JPDA); LiDAR como terceira fonte.

Estado do LAFusion: 10 páginas escritas (limite do CFP é 12), prazo 04/09/2026, Springer CCIS, double-blind via CMT. Em 16/08 a calibração da câmera foi corrigida: com os 4 intrínsecos livres estava mal-condicionada (f_x 33% acima do esperado), o caso degenerado de Zhang (2000), já que a câmera fixa deixa o tabuleiro sempre fronto-paralelo. Fixamos os intrínsecos no valor nominal e calibramos só a distorção; o resultado reproduz a projeção de produção a menos de 0,001m e nenhum resultado publicado muda.

Conclusão: no LARS, o *action masking* refuta a explicação mais plausível a priori para o resultado negativo e redireciona o diagnóstico para o espaço de ação e o orçamento de treino. No LAFusion, o ganho de +23,7% na correção convive com uma perda de -12,7% medida continuamente, e a teoria de filtragem sob observação intermitente explica a reversão. Os dois trabalhos reportam o resultado completo e o fundamentam.