

# CERISE — Dois Trabalhos, Uma Base Comum

LARS 2026 (alocação de tarefas via RL) e LAFusion 2026 (fusão sensorial via EKF)

Yan Santos Leite

Orientador: Prof. Alisson Assis Cardoso

Escola de Engenharia Elétrica, Mecânica e de Computação (EMC) — UFG  
Fundação de Amparo à Pesquisa do Estado de Goiás (FAPEG)

16 de agosto de 2026

# Roteiro e visão geral dos dois trabalhos

Esta apresentação cobre a trajetória completa de dois trabalhos que compartilham a mesma base de código e a mesma plataforma física (três TurtleBot3 no CERISE), mas respondem a perguntas de pesquisa diferentes. Segue nesta ordem: (1) LARS 2026, da concepção à submissão (06/08); (2) LAFusion 2026, da concepção ao estado atual (16/08); (3) uma conclusão com os próximos passos de cada um.

|            | <b>LARS 2026</b>                                      | <b>LAFusion 2026</b>                                              |
|------------|-------------------------------------------------------|-------------------------------------------------------------------|
| Pergunta   | RL supera a heurística gulosa na alocação de tarefas? | Como o EKF se comporta quando a taxa de detecção do YOLO é baixa? |
| Método     | PPO (Stable-Baselines3)                               | Extended Kalman Filter por robô                                   |
| Plataforma | 3 TurtleBot3, ROS2/Gazebo                             | 3 TurtleBot3, ROS2/Gazebo                                         |
| Estado     | Submetido no EasyChair em 06/08                       | Prazo de submissão 04/09                                          |

# Tese, argumentação e contribuições

**Tese central.** Rigor metodológico — teste causal, fundamentação teórica explícita — sustenta um resultado negativo ou misto melhor do que uma alegação de vitória sem teste.

## Como a tese se sustenta:


- ▶ **LARS:** testa a hipótese de que RL supera a heurística, encontra o oposto, e usa um experimento causal (*action masking*) para refutar a explicação mais plausível a priori.
- ▶ **LAFusion:** mede tanto o ganho de +23,7% pontual quanto a degradação de -12,7% contínua sob baixa taxa de detecção do YOLO, e explica essa reversão com a teoria prévia de filtragem sob observação intermitente.

**Contribuições:** (1) um gêmeo digital câmera+YOLO validado ( $mAP@0,5=0,995$ , erro de 4,7 cm), base comum aos dois trabalhos; (2) um diagnóstico causal de por que o PPO perde em MRTA com  $N = 3$ , isolando o espaço de ação pequeno como fator dominante; (3) uma avaliação do EKF sob baixa taxa de detecção do YOLO em duas frentes: +23,7% de ganho nos instantes de correção e -12,7% de erro medido continuamente.


# LARS — Motivação e arquitetura

**O problema.** MRTA (*Multi-Robot Task Allocation*: decidir qual robô de uma frota atende cada demanda que chega) é resolvida na prática por heurísticas gulosas, que escolhem o robô livre mais próximo e são míopes a demandas futuras. **Hipótese:** um PPO com antecipação de duas demandas futuras supera a heurística *nearest-free* em tempo de resposta.

**Treino** (offline, sem câmera):




**Inferência** (produção, ROS2):



`rl/allocation_env.py` é um ambiente Gymnasium (a biblioteca padrão para treino de RL: define `reset()` e `step(ação)`, que qualquer algoritmo — aqui o PPO — sabe treinar contra) do tipo *analítico*, sem ROS nem Gazebo: seu `step()` é aritmética pura, treina 500k timesteps em minutos em vez de dias, e não recebe nenhum

# LARS — Gêmeo digital: erro de localização câmera+YOLO




|               |               |
|---------------|---------------|
| mAP@0.5       | <b>0,995</b>  |
| Erro estático | 1,24 cm       |
| Erro dinâmico | <b>4,7 cm</b> |
| Det. <15 cm   | 100%          |

É o erro dinâmico de 4,7 cm (rastreo contínuo), não o estático, que alimenta os experimentos seguintes. O salto entre os dois regimes vem de motion blur e de latência — o detector em si mede bem tanto parado quanto em movimento. Verdade e predição seguem bem comportadas mesmo com múltiplos robôs próximos, evidência qualitativa contra outliers que a média poderia esconder.

# LARS — Por que PPO $\neq$ nearest-free na prática

## Comparação de políticas — seed=0



Mesmo estado (3 robôs, mesma demanda D), gerado a partir do AllocationEnv real. À esquerda, *nearest\_free* escolhe sempre o robô livre mais próximo, por construção (R2); à direita, o PPO treinado antecipa as 2 próximas demandas da fila e pode escolher diferente (R1). É essa divergência de decisão que a hipótese central do LARS testa.

# LARS — Formulação do MDP e protocolo experimental

**Estado (21D):**  $3N + 4 + 4 \times 2$  para  $N = 3$  — a posição e o tempo livre de cada robô, a origem e o destino da demanda atual, e a origem e o destino das **2 próximas demandas** já visíveis na fila. Essa antecipação é o que permite à política decidir “*segurar*” um robô livre à espera de uma demanda melhor. **Ação:** escolha discreta de qual robô atende a demanda. **Recompensa:**  $r = -(t_{espera} + t_{viagem})$ , o *tempo de resposta* completo. A formulação original penalizava só o tempo de viagem — um bug de causa-raiz corrigido antes do primeiro resultado válido.

**Treino:** PPO via Stable-Baselines3, com hiperparâmetros padrão ( $\text{lr } 3 \times 10^{-4}$ ,  $\gamma = 0,99$ , 8 envs paralelos, seed 42) e 500k timesteps ( $\sim 2\text{h}$  de CPU). Esses defaults isolam o efeito da fonte de observação e do masking; buscar o teto de desempenho do próprio PPO fica para trabalho futuro.



**Estatística:** 1000 episódios pareados, com Wilcoxon signed-rank, Cliff's  $\delta$  e IC 95% bootstrap. O pareamento é necessário porque, em RL profundo, a variância entre sementes já produz diferenças significativas por conta própria.

**Robustez:** 6 regimes de carga (30s–10s), 500 episódios por ponto. **Por que PPO e não SAC/DQN:** o experimento isola o efeito da fonte de observação e do masking sobre um único algoritmo. PPO é o padrão de fato em SB3 e tem suporte nativo a masking (MaskablePPO), necessário para o teste causal a seguir.

# LARS — Resultado: achado negativo e robustez

| Política     | Resp.   | p95     | Desbal.      |
|--------------|---------|---------|--------------|
| Nearest-free | 17,86 s | 27,77 s | 0,149        |
| PPO (YOLO)   | 20,01 s | 29,46 s | <b>0,135</b> |
| PPO (odom)   | 19,83 s | 29,37 s | <b>0,135</b> |

Carga moderada, 1000 episódios pareados, Wilcoxon  $p < 0,001$ . **O guloso vence:** o tempo de resposta do PPO é **~12% pior**. A proximidade entre PPO(YOLO) e PPO(odom) indica que o ruído do gêmeo digital é só um efeito de segunda ordem — a causa principal está em outro lugar.



O boxplot mostra uma razão p95/média comparável entre as políticas ( $\approx 1,47-1,56$ ): a desvantagem do PPO vem de um deslocamento de toda a distribuição, e não de uma cauda catastrófica isolada. Sob carga, o gap encolhe de +19,0% para +7,7%, mas o guloso permanece mais rápido em todo o intervalo testado.



# LARS — Diagnóstico causal, limitações e fechamento

Três explicações investigadas: (1) restrição suave vs. rígida — o guloso nunca escolhe robô ocupado, por construção, enquanto o PPO erra em 4,2% das decisões contra 0,3% do guloso ( $\sim 13\times$  mais), o maior contribuinte isolado; (2) espaço de ação pequeno — com  $N = 3$ , no máximo três alternativas por decisão; (3) orçamento de treino — aprendizado claro, mas sem convergência.

Teste causal: PPO(YOLO, masked), com ação restrita a robôs livres via *action masking* (MaskablePPO), sob os mesmos hiperparâmetros e orçamento.

|                             | Sem masking | Com masking |
|-----------------------------|-------------|-------------|
| Taxa de ação inválida       | 4,2%        | 0,0%        |
| Gap vs. guloso              | $\sim 12\%$ | $\sim 11\%$ |
| Cliff's $\delta$ vs. guloso | 0,703       | 0,636       |


Hipótese causal refutada: o masking zera a taxa de ação inválida, mas o gap melhora só  $\sim 1$  ponto percentual. O peso da explicação volta então para o espaço de ação pequeno e para o orçamento de treino.

Limitações assumidas: (1) hiperparâmetros padrão do PPO, aquém do teto possível do RL para o problema; (2) resultados válidos para  $N = 3$ , sem extrapolação para frotas grandes; (3) ausência de validação em hardware físico; (4) 500k timesteps sem convergência. Todas são alvo direto de trabalho futuro.

Revisão de literatura: 330 estudos triados (Scopus, IEEE, arXiv, ACM), resultando em 117 aceitos e 213 rejeitados. Submissão: 06/08/2026, no EasyChair, com aceite previsto para 15/09/2026. O próprio título já declara o método (*Causal Diagnosis...*), sem alegar vitória do RL.

Por que um segundo paper: o LARS usa a posição do YOLO como estado observado, mas nunca pergunta o que fazer quando a detecção não está disponível. Em produção, um fallback discreto descarta essa informação, sem correção parcial e sem propagação formal de incerteza. A pergunta do LAFusion: como se comporta um EKF que funde as duas fontes probabilisticamente, quando a taxa de detecção do YOLO é baixa?

# LA Fusion — Arquitetura e pipeline



`yolo_detector.py` já converte pixel→mundo (via `projection.py`) antes de publicar `/robot_detections` — `association.py` e `ekf_fusion_node.py` nunca importam `projection.py` diretamente. A seta tracejada mostra que o EKF publica pose a cada leitura de odometria (predição), não só após uma correção YOLO bem-sucedida.

## Módulos reais do código:

- ▶ `ekf_fusion_node.py`: nó ROS2 de produção, com um EKF independente por robô — predição via odometria, correção via detecção YOLO.
- ▶ `association.py`: gating de Mahalanobis (distância que pondera o erro entre detecção e posição estimada pela covariância  $P + R$  do filtro, em vez de metros brutos — evita que um robô “roube” a detecção de outro só por estar mais perto em linha reta), compartilhado entre o EKF e o nó de avaliação offline.
- ▶ `projection.py`: projeção pixel↔mundo usada dentro de `yolo_detector.py`, com duas implementações (heurística por FOV e via intrínsecos calibrados) confirmadas geometricamente equivalentes.

**Por que EKF, e não UKF ou filtro de partículas:** o modelo de observação da câmera é quase linear, já que é uma projeção pinhole numa cena essencialmente planar. O ganho de um UKF, que mira a não-linearidade do modelo de observação, seria marginal aqui. O problema central deste trabalho é o ruído de observação, não o

# LA Fusion — Design do EKF

**Estado:**  $x_k = [p_x, p_y, \theta]^\top$  por robô. A predição integra o *delta* de leituras consecutivas de odometria sobre o estado atual, e não o valor absoluto — isso preserva correções visuais anteriores, que seriam descartadas a cada ciclo se usássemos o valor absoluto.

## Hiperparâmetros e sua origem:

- ▶  $Q = \text{diag}(0,5, 0,5, 0,25)$ , calibrado empiricamente contra dados reais numa varredura de  $10^{-6}$  a  $1,0$ : o ganho cresce monotonicamente até saturar em  $Q \geq 0,5$ .
- ▶ Teto de covariância  $\text{clip}(P, -\infty, 0,05)$ . Sem ele,  $P$  cresce sem limite em intervalos longos sem correção (chegamos a observar traço  $\approx 85$  contra o esperado  $\approx 0,5$ ), o que quebra o gating de Mahalanobis ao alargar a região de aceitação até um robô “roubar” a detecção do vizinho.
- ▶ Limiar de gating  $d^2 \leq 9,21$ , o valor padrão do teste  $\chi^2$  com 2 graus de liberdade a 99% de confiança.
- ▶ Atualização de  $P$  pela **forma de Joseph**  $(I - KH)P(I - KH)^\top + KRK^\top$ , e gating com  $S = P + R$ : duas correções de rigor numérico aplicadas nesta sessão (17/08/2026) que reproduzem exatamente os mesmos resultados já publicados.

# LA Fusion — Testes e validação


**Validação sintética (antes de qualquer dado real):** Monte Carlo com 30 sementes, 2000 passos cada, contra trajetória sintética com verdade terrestre conhecida.

| Estat. | Obtido | Esperado   |
|--------|--------|------------|
| NEES   | 2,955  | 3,0 (1,5%) |
| NIS    | 1,982  | 2,0 (0,9%) |

*Por que validar sinteticamente antes do dado real:* isso isola bugs de implementação de problemas de dado — um filtro mal calibrado contra dados sintéticos jamais seria confiável contra dados reais, ainda mais ruidosos.

**Dados reais:** 3 cenários gravados no Gazebo (parado, reto, curva/occlusão), com 3 robôs e sincronização de timestamp verificada — nenhum gap acima de 500ms.

**Sobre benchmarks públicos:** não avaliamos contra UTIAS MRCLAM ou S3E, pois ambos assumem sensor embarcado em cada robô (range-bearing ou LiDAR/estéreo/IMU onboard): nosso cenário usa câmera externa



NEES/NIS ao longo dos 2000 passos, com o valor esperado teórico e a faixa de confiança de 95%. A tabela ao lado mostra só a média agregada das 30 sementes; esta figura confirma que a consistência do filtro se mantém estável do início ao fim da corrida, e não apenas num regime transitório inicial, antes de aplicá-lo aos dados reais.


# LA Fusion — Resultado principal

| Drift     | Méd. EKF/Odom | $\Delta$      | RMSE EKF/Odom |
|-----------|---------------|---------------|---------------|
| Nenhum    | 0,036/0,000   | N/A           | 0,052/0,000   |
| Leve      | 0,053/0,050   | -5,3%         | 0,068/0,066   |
| Agressivo | 0,128/0,168   | <b>+23,7%</b> | 0,163/0,195   |

**Table:** Erro de posição (m) nos instantes de correção YOLO, 3 cenários ( $n = 1323$ ). Wilcoxon  $p < 0,001$  sob drift agressivo.

Sob drift agressivo, o EKF reduz o erro médio em **+23,7%** frente à odometria pura.

*Por que o ganho é negativo sob drift leve (-5,3%):* nesse regime, o erro de detecção visual ( $\approx 3-6$  cm) ainda é maior que o erro de uma odometria pouco corrompida, então fundir as duas pode até piorar levemente o resultado. Isso é o comportamento esperado de um filtro corretamente calibrado.



Cenário 1 (preto) sob drift agressivo: EKF (azul) vs. odometria com drift (laranja, tracejada) vs. verdade terrestre (preto). A tabela reduz o ganho a um número agregado; aqui está o mecanismo por trás dele — a odometria se afasta do caminho real enquanto o EKF permanece próximo, evidência qualitativa de que o filtro de fato corrige o drift, além de melhorar a métrica agregada.

# LA Fusion — Achado central: o erro contínuo

| Cenário         | Cobertura | Média EKF/Odom       | $\Delta$      | RMSE EKF/Odom        | $\Delta$ RMSE |
|-----------------|-----------|----------------------|---------------|----------------------|---------------|
| Parado          | 27,6%     | 0,212 / 0,177        | −19,3%        | 0,246 / 0,205        | −19,8%        |
| Reto            | 11,3%     | 0,212 / 0,178        | −18,8%        | 0,245 / 0,206        | −19,2%        |
| Curva/occlusão  | 0,0%      | 0,178 / 0,178        | −0,0%         | 0,205 / 0,205        | −0,0%         |
| <b>Agregado</b> | —         | <b>0,200 / 0,178</b> | <b>−12,7%</b> | <b>0,233 / 0,205</b> | <b>−13,4%</b> |


**Table:** Erro medido a CADA leitura de odometria, não só nos instantes de correção ( $n = 1607$ , Wilcoxon  $p < 0,001$ ).

Medido continuamente, o mesmo filtro é **12,7% pior** que a odometria pura — o sinal se inverte em relação ao slide anterior. No cenário de 0% de cobertura, a mudança é exatamente 0,0%: sem correções, a predição do EKF degenera matematicamente para integração pura de delta-odometria, idêntica à baseline não fundida, o que confirma o mecanismo em vez de ser coincidência.

**ATE vs. RPE (Sturm et al. 2012):** o erro acima é ATE, erro absoluto por amostra. O RPE, drift entre passos consecutivos, também piora, mas bem menos (−4,2%/ − 4,8% agregado). Isso indica que a reversão vem sobretudo de erro *acumulando* sob correção esparsa, já que cada passo individual, isoladamente, drifta pouco mais que a odometria.

**O ponto do trabalho é justamente reportar as duas métricas, e não só a favorável.**

# LA Fusion — Por que o erro contínuo piora (fundamentação teórica)



A covariância satura no teto quase imediatamente após qualquer intervalo sem correção. Sinopoli et al. (2004) mostram que a covariância diverge abaixo de uma taxa crítica de observação, e nosso cenário de 0% de cobertura está exatamente no caso-limite  $p \rightarrow 0$ . O teto evita esse crescimento ilimitado, mas limita só a *estimativa de incerteza do próprio filtro*: o filtro fica excessivamente confiante na predição só-odometria, enquanto a estimativa de estado em si segue imprecisa. Dissanayake et al. (2001) provam convergência do EKF-SLAM sob observação *densa*, uma premissa que nossa câmera viola por construção (0–28% de cobertura).

**Por que UKF/partículas/IMM não resolvem:** um filtro de partículas degenera para propagação pura, sem verossimilhança para reponderar; um UKF mira a não-linearidade do modelo de observação, que não é o problema aqui; e um IMM ainda precisa de alguma observação para ponderar seus modos concorrentes. A causa raiz é a topologia do sensor — um único ponto de vista, sujeito a oclusão —, não a escolha do filtro.

# LA Fusion — Estado atual: correção da calibração de câmera

**Achado desta sessão (16/08):** a calibração original, com os 4 intrínsecos livres ( $f_x, f_y, c_x, c_y$ ), estava mal-condicionada:  $f_x$  ficou 33% acima do valor geometricamente esperado, apesar de um erro de reprojeção baixo (0,162px).

*Causa raiz:* com a câmera fixa olhando reto para baixo, o tabuleiro de calibração fica sempre fronto-paralelo ao sensor em todas as poses. Esse é o caso degenerado clássico do método de Zhang (2000) — sem variação de inclinação relativa entre sensor e alvo,  $f_x$  e a distância percebida ficam quase linearmente dependentes.

**Correção aplicada:** como a geometria da câmera simulada já era conhecida com precisão (altura e campo de visão nominais exatos), fixamos  $f_x, f_y, c_x, c_y$  no valor geométrico nominal e calibramos apenas a distorção. Esse é o remédio padrão quando os intrínsecos nominais já são confiáveis.

**Resultado:** a calibração corrigida reproduz a projeção heurística já usada em produção a menos de 0,001m de diferença, o que confirma a equivalência geométrica entre as duas.

**Nenhum resultado já publicado no paper muda** — a heurística de produção nunca esteve errada, e só uma calibração alternativa em teste é que estava mal-condicionada.

**Estado:** paper com 8 páginas escritas (limite real do CFP é 12), prazo de submissão **04/09/2026**, formato Springer CCIS, revisão double-blind via Microsoft CMT.



# Referências-chave e próximos passos

## LARS — bibliografia essencial:

- ▶ Henderson et al. (2018): reprodutibilidade em RL profundo, motiva o teste pareado.
- ▶ Huang & Ontañón (2022): action masking produz gradiente válido; no nosso domínio elimina a violação sem fechar o gap.
- ▶ Agrawal et al. (2023, RTAW), Paul et al. (2022, Capsule Attention): arquiteturas atencionais como direção futura.

Próximos passos: aguardar aceite (15/09/2026); espaço de ação e orçamento de treino maiores; formulação Dec-POMDP (CTDE).

## LA Fusion — bibliografia essencial:

- ▶ Sinopoli (2004), Bailey & Durrant-Whyte (2006), Dissanayake et al. (2001): fundamentação teórica clássica do achado central (erro contínuo, modelo EKF, convergência sob observação densa).
- ▶ Khosravi et al. (2026): localização cooperativa com fusão assíncrona, cenário mais próximo do nosso.
- ▶ Ahmed & Frémont (2026): rastreo multi-robô descentralizado, mesma classe de problema.
- ▶ Dobrynin & Garcia (2025): testbed TurtleBot3 com EKF distribuído.

Próximos passos: submissão no CMT até 04/09/2026;  $Q$  adaptativo por tempo desde a última correção; Jacobiano completo na projeção; associação robusta (Hungarian/JPDA); LiDAR como terceira fonte.

---

**Conclusão — LARS:** um resultado negativo, testado e explicado causalmente. O *action masking* refuta a explicação mais plausível a priori, redirecionando o diagnóstico para o espaço de ação pequeno e o orçamento de treino. **LA Fusion:** um ganho real nos instantes de correção (+23,7%), mas mensuravelmente pior que a odometria pura quando avaliado continuamente (−12,7%). A teoria estabelecida de filtragem sob observação intermitente explica essa reversão como comportamento esperado do filtro, e não como falha de implementação. Os dois trabalhos compartilham o mesmo padrão: reportar o resultado completo, favorável ou não, e fundamentá-lo.