

CERISE — Dois Trabalhos, Uma Base Comum

LARS 2026 (alocação de tarefas via RL) e LAFusion 2026 (fusão sensorial via EKF)

Yan Santos Leite

Orientador: Prof. Alisson Assis Cardoso

Escola de Engenharia Elétrica, Mecânica e de Computação (EMC) — UFG
Fundação de Amparo à Pesquisa do Estado de Goiás (FAPEG)

16 de agosto de 2026

Roteiro e visão geral dos dois trabalhos

Esta apresentação cobre a trajetória completa de dois trabalhos que compartilham a mesma base de código e a mesma plataforma física (três TurtleBot3 no CERISE), mas respondem a perguntas de pesquisa diferentes. Segue nesta ordem: (1) LARS 2026, da concepção à submissão (06/08); (2) LAFusion 2026, da concepção ao estado atual (16/08); (3) uma conclusão com os próximos passos de cada um.

	LARS 2026	LAFusion 2026
Pergunta	RL supera a heurística gulosa na alocação de tarefas?	Como o EKF se comporta quando a taxa de detecção do YOLO é baixa?
Método	PPO (Stable-Baselines3)	Extended Kalman Filter por robô
Plataforma	3 TurtleBot3, ROS2/Gazebo	3 TurtleBot3, ROS2/Gazebo
Estado	Submetido no EasyChair em 06/08	Prazo de submissão 04/09

Tese, argumentação e contribuições

Tese central. Rigor metodológico — teste causal, fundamentação teórica explícita — sustenta um resultado negativo ou misto melhor do que uma alegação de vitória sem teste.

Como a tese se sustenta:


- ▶ **LARS:** testa a hipótese de que RL supera a heurística, encontra o oposto, e usa um experimento causal (*action masking*) para refutar a explicação mais plausível a priori.
- ▶ **LAFusion:** mede tanto o ganho de +23,7% pontual quanto a degradação de -12,7% contínua sob baixa taxa de detecção do YOLO, e explica essa reversão com a teoria prévia de filtragem sob observação intermitente.

Contribuições: (1) um gêmeo digital câmera+YOLO validado ($mAP@0,5=0,995$, erro de 4,7 cm), base comum aos dois trabalhos; (2) um diagnóstico causal de por que o PPO perde em MRTA com $N = 3$, isolando o espaço de ação pequeno como fator dominante; (3) uma avaliação do EKF sob baixa taxa de detecção do YOLO em duas frentes: +23,7% de ganho nos instantes de correção e -12,7% de erro medido continuamente.

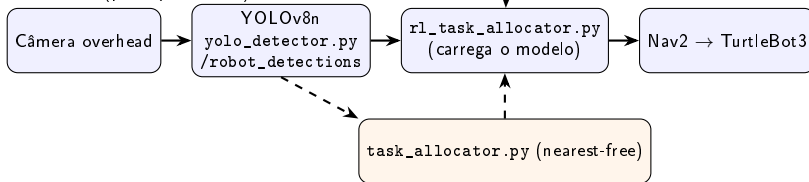
LARS — Motivação e arquitetura

O problema. MRTA (*Multi-Robot Task Allocation*: decidir qual robô de uma frota atende cada demanda que chega) é resolvida na prática por heurísticas gulosas, que escolhem o robô livre mais próximo e são míopes a demandas futuras. **Hipótese:** um PPO com antecipação de duas demandas futuras supera a heurística *nearest-free* em tempo de resposta.

Treino (offline, sem câmera):




Inferência (produção, ROS2):



rl/allocation_env.py é um ambiente Gymnasium (a biblioteca padrão para treino de RL: define `reset()` e `step(ação)`, que qualquer algoritmo — aqui o PPO — sabe treinar contra) do tipo *analítico*, sem ROS nem Gazebo: seu `step()` é aritmética pura, treina 500k timesteps em minutos em vez de dias, e não recebe nenhum

LARS — Gêmeo digital: erro de localização câmera+YOLO




mAP@0.5	0,995
Erro estático	1,24 cm
Erro dinâmico	4,7 cm
Det. <15 cm	100%

É o erro dinâmico de 4,7 cm (rastreo contínuo), não o estático, que alimenta os experimentos seguintes. O salto entre os dois regimes vem de motion blur e de latência — o detector em si mede bem tanto parado quanto em movimento. Verdade e predição seguem bem comportadas mesmo com múltiplos robôs próximos, evidência qualitativa contra outliers que a média poderia esconder.

LARS — Por que PPO $\neq$ nearest-free na prática

Comparação de políticas — seed=0



Mesmo estado (3 robôs, mesma demanda D), gerado a partir do AllocationEnv real. À esquerda, *nearest_free* escolhe sempre o robô livre mais próximo, por construção (R2); à direita, o PPO treinado antecipa as 2 próximas demandas da fila e pode escolher diferente (R1). É essa divergência de decisão que a hipótese central do LARS testa.

LARS — Formulação do MDP e protocolo experimental

Estado (21D): $3N + 4 + 4 \times 2$ para $N = 3$ — a posição e o tempo livre de cada robô, a origem e o destino da demanda atual, e a origem e o destino das **2 próximas demandas** já visíveis na fila. Essa antecipação é o que permite à política decidir “*segurar*” um robô livre à espera de uma demanda melhor. **Ação:** escolha discreta de qual robô atende a demanda. **Recompensa:** $r = -(t_{espera} + t_{viagem})$, o *tempo de resposta* completo. A formulação original penalizava só o tempo de viagem — um bug de causa-raiz corrigido antes do primeiro resultado válido.

Treino: PPO via Stable-Baselines3, com hiperparâmetros padrão ($\text{lr } 3 \times 10^{-4}$, $\gamma = 0,99$, 8 envs paralelos, seed 42) e 500k timesteps ($\sim 2\text{h}$ de CPU). Esses defaults isolam o efeito da fonte de observação e do masking; buscar o teto de desempenho do próprio PPO fica para trabalho futuro.



Estatística: 1000 episódios pareados, com Wilcoxon signed-rank, Cliff's δ e IC 95% bootstrap. O pareamento é necessário porque, em RL profundo, a variância entre sementes já produz diferenças significativas por conta própria.

Robustez: 6 regimes de carga (30s–10s), 500 episódios por ponto. **Por que PPO e não SAC/DQN:** o experimento isola o efeito da fonte de observação e do masking sobre um único algoritmo. PPO é o padrão de fato em SB3 e tem suporte nativo a masking (MaskablePPO), necessário para o teste causal a seguir.

LARS — Resultado: achado negativo e robustez

Política	Resp.	p95	Desbal.
Nearest-free	17,86 s	27,77 s	0,149
PPO (YOLO)	20,01 s	29,46 s	0,135
PPO (odom)	19,83 s	29,37 s	0,135

Carga moderada, 1000 episódios pareados, Wilcoxon $p < 0,001$. **O guloso vence:** o tempo de resposta do PPO é **~12% pior**. A proximidade entre PPO(YOLO) e PPO(odom) indica que o ruído do gêmeo digital é só um efeito de segunda ordem — a causa principal está em outro lugar.



O boxplot mostra uma razão p95/média comparável entre as políticas ($\approx 1,47-1,56$): a desvantagem do PPO vem de um deslocamento de toda a distribuição, e não de uma cauda catastrófica isolada. Sob carga, o gap encolhe de +19,0% para +7,7%, mas o guloso permanece mais rápido em todo o intervalo testado.

LARS — Diagnóstico causal, limitações e fechamento

Três explicações investigadas: (1) restrição suave vs. rígida — o guloso nunca escolhe robô ocupado, por construção, enquanto o PPO erra em 4,2% das decisões contra 0,3% do guloso ($\sim 13\times$ mais), o maior contribuinte isolado; (2) espaço de ação pequeno — com $N = 3$, no máximo três alternativas por decisão; (3) orçamento de treino — aprendizado claro, mas sem convergência.

Teste causal: PPO(YOLO, masked), com ação restrita a robôs livres via *action masking* (MaskablePPO), sob os mesmos hiperparâmetros e orçamento.

	Sem masking	Com masking
Taxa de ação inválida	4,2%	0,0%
Gap vs. guloso	$\sim 12\%$	$\sim 11\%$
Cliff's δ vs. guloso	0,703	0,636

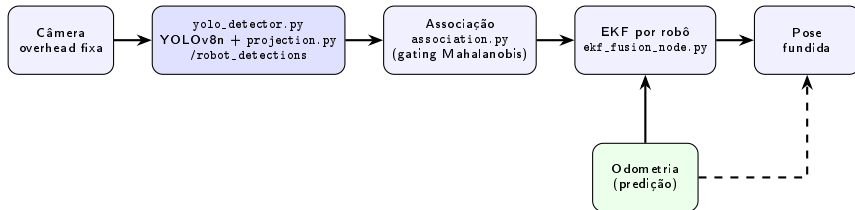
Hipótese causal refutada: o masking zera a taxa de ação inválida, mas o gap melhora só ~ 1 ponto percentual. O peso da explicação volta então para o espaço de ação pequeno e para o orçamento de treino.

Limitações assumidas: (1) hiperparâmetros padrão do PPO, alguém do teto possível do RL para o problema; (2) resultados válidos para $N = 3$, sem extrapolação para frotas grandes; (3) ausência de validação em hardware físico; (4) 500k timesteps sem convergência. Todas são alvo direto de trabalho futuro.

Revisão de literatura: 330 estudos triados (Scopus, IEEE, arXiv, ACM), resultando em 117 aceitos e 213 rejeitados. Submissão: 06/08/2026, no EasyChair, com aceite previsto para 15/09/2026. O próprio título já declara o método (*Causal Diagnosis...*), sem alegar vitória do RL.

Por que um segundo paper: o LARS usa a posição do YOLO como estado observado, mas nunca pergunta o que fazer quando a detecção não está disponível. Em produção, um fallback discreto descarta essa informação, sem correção parcial e sem propagação formal de incerteza. A pergunta do LAFusion: como se comporta um EKF que funde as duas fontes probabilisticamente, quando a taxa de detecção do YOLO é baixa?

LA Fusion — Arquitetura e pipeline



`yolo_detector.py` já converte pixel→mundo (via `projection.py`) antes de publicar `/robot_detections` — `association.py` e `ekf_fusion_node.py` nunca importam `projection.py` diretamente. A seta tracejada mostra que o EKF publica pose a cada leitura de odometria (predição), não só após uma correção YOLO bem-sucedida.

Módulos reais do código:

- ▶ `ekf_fusion_node.py`: nó ROS2 de produção, com um EKF independente por robô — predição via odometria, correção via detecção YOLO.
- ▶ `association.py`: gating de Mahalanobis (distância que pondera o erro entre detecção e posição estimada pela covariância $P + R$ do filtro, em vez de metros brutos — evita que um robô “roube” a detecção de outro só por estar mais perto em linha reta), compartilhado entre o EKF e o nó de avaliação offline.
- ▶ `projection.py`: projeção pixel↔mundo usada dentro de `yolo_detector.py`, com duas implementações (heurística por FOV e via intrínsecos calibrados) confirmadas geometricamente equivalentes.

Por que EKF, e não UKF ou filtro de partículas: o modelo de observação da câmera é quase linear, já que é uma projeção pinhole numa cena essencialmente planar. O ganho de um UKF, que mira a não-linearidade do modelo de observação, seria marginal aqui. O problema central deste trabalho é o ruído de observação, não o

LA Fusion — Design do EKF

Estado: $x_k = [p_x, p_y, \theta]^\top$ por robô. A predição integra o *delta* de leituras consecutivas de odometria sobre o estado atual, e não o valor absoluto — isso preserva correções visuais anteriores, que seriam descartadas a cada ciclo se usássemos o valor absoluto.

Hiperparâmetros e sua origem:

- ▶ $Q = \text{diag}(0,5, 0,5, 0,25)$, calibrado empiricamente contra dados reais numa varredura de 10^{-6} a $1,0$: o ganho cresce monotonicamente até saturar em $Q \geq 0,5$.
- ▶ Teto de covariância $\text{clip}(P, -\infty, 0,05)$. Sem ele, P cresce sem limite em intervalos longos sem correção (chegamos a observar traço ≈ 85 contra o esperado $\approx 0,5$), o que quebra o gating de Mahalanobis ao alargar a região de aceitação até um robô “roubar” a detecção do vizinho.
- ▶ Limiar de gating $d^2 \leq 9,21$, o valor padrão do teste χ^2 com 2 graus de liberdade a 99% de confiança.
- ▶ Atualização de P pela **forma de Joseph** $(I - KH)P(I - KH)^\top + KRK^\top$, e gating com $S = P + R$: duas correções de rigor numérico aplicadas nesta sessão (17/08/2026) que reproduzem exatamente os mesmos resultados já publicados.

LA Fusion — Testes e validação


Validação sintética (antes de qualquer dado real): Monte Carlo com 30 sementes, 2000 passos cada, contra trajetória sintética com verdade terrestre conhecida.

Estat.	Obtido	Esperado
NEES	2,955	3,0 (1,5%)
NIS	1,982	2,0 (0,9%)

Por que validar sinteticamente antes do dado real: isso isola bugs de implementação de problemas de dado — um filtro mal calibrado contra dados sintéticos jamais seria confiável contra dados reais, ainda mais ruidosos.

Dados reais: 3 cenários gravados no Gazebo (parado, reto, curva/occlusão), com 3 robôs e sincronização de timestamp verificada — nenhum gap acima de 500ms.

Sobre benchmarks públicos: não avaliamos contra UTIAS MRCLAM ou S3E, pois ambos assumem sensor embarcado em cada robô (range-bearing ou LiDAR/estéreo/IMU onboard): nosso cenário usa câmera externa



NEES/NIS ao longo dos 2000 passos, com o valor esperado teórico e a faixa de confiança de 95% *por amostra individual* (mais larga que o critério da média agregada da tabela — os picos que chegam perto do teto são esperados nessa escala, não uma inconsistência). A tabela ao lado mostra só a média agregada das 30 sementes; esta figura confirma que a consistência do filtro se mantém estável do início ao fim da corrida, e não apenas num regime transitório inicial, antes de aplicá-lo aos dados reais.


LA Fusion — Resultado principal

Drift	Méd. EKF/Odom	Δ	RMSE EKF/Odom
Nenhum	0,036/0,000	N/A	0,052/0,000
Leve	0,053/0,050	-5,3%	0,068/0,066
Agressivo	0,128/0,168	+23,7%	0,163/0,195

Table: Erro de posição (m) nos instantes de correção YOLO, 3 cenários ($n = 1323$). Wilcoxon $p < 0,001$ sob drift agressivo.

Sob drift agressivo, o EKF reduz o erro médio em **+23,7%** frente à odometria pura.

Por que o ganho é negativo sob drift leve (-5,3%): nesse regime, o erro de detecção visual ($\approx 3-6$ cm) ainda é maior que o erro de uma odometria pouco corrompida, então fundir as duas pode até piorar levemente o resultado. Isso é o comportamento esperado de um filtro corretamente calibrado.



Cenário 1 (preto) sob drift agressivo: EKF (azul) vs. odometria com drift (laranja, tracejada) vs. verdade terrestre (preto). A tabela reduz o ganho a um número agregado; aqui está o mecanismo por trás dele — a odometria se afasta do caminho real enquanto o EKF permanece próximo, evidência qualitativa de que o filtro de fato corrige o drift, além de melhorar a métrica agregada.

LA Fusion — Achado central: o erro contínuo

Cenário	Cobertura	Média EKF/Odom	Δ	RMSE EKF/Odom	Δ RMSE
Parado	27,6%	0,212 / 0,177	−19,3%	0,246 / 0,205	−19,8%
Reto	11,3%	0,212 / 0,178	−18,8%	0,245 / 0,206	−19,2%
Curva/occlusão	0,0%	0,178 / 0,178	−0,0%	0,205 / 0,205	−0,0%
Agregado	—	0,200 / 0,178	−12,7%	0,233 / 0,205	−13,4%


Table: Erro medido a CADA leitura de odometria, não só nos instantes de correção ($n = 1607$, Wilcoxon $p < 0,001$).

Medido continuamente, o mesmo filtro é **12,7% pior** que a odometria pura — o sinal se inverte em relação ao slide anterior. No cenário de 0% de cobertura, a mudança é exatamente 0,0%: sem correções, a predição do EKF degenera matematicamente para integração pura de delta-odometria, idêntica à baseline não fundida, o que confirma o mecanismo em vez de ser coincidência.

ATE vs. RPE (Sturm et al. 2012): o erro acima é ATE, erro absoluto por amostra. O RPE, drift entre passos consecutivos, também piora, mas bem menos (−4,2%/ − 4,8% agregado). Isso indica que a reversão vem sobretudo de erro *acumulando* sob correção esparsa, já que cada passo individual, isoladamente, drifta pouco mais que a odometria.

O ponto do trabalho é justamente reportar as duas métricas, e não só a favorável.

LA Fusion — Por que o erro contínuo piora (fundamentação teórica)



A covariância satura no teto quase imediatamente após qualquer intervalo sem correção. Sinopoli et al. (2004) mostram que a covariância diverge abaixo de uma taxa crítica de observação, e nosso cenário de 0% de cobertura está exatamente no caso-limite $p \rightarrow 0$. O teto evita esse crescimento ilimitado, mas limita só a *estimativa de incerteza do próprio filtro*: o filtro fica excessivamente confiante na predição só-odometria, enquanto a estimativa de estado em si segue imprecisa. Dissanayake et al. (2001) provam convergência do EKF-SLAM sob observação *densa*, uma premissa que nossa câmera viola por construção (0–28% de cobertura).

Por que UKF/partículas/IMM não resolvem: um filtro de partículas degenera para propagação pura, sem verossimilhança para reponderar; um UKF mira a não-linearidade do modelo de observação, que não é o problema aqui; e um IMM ainda precisa de alguma observação para ponderar seus modos concorrentes. A causa raiz é a topologia do sensor — um único ponto de vista, sujeito a oclusão —, não a escolha do filtro.

LA Fusion — Estado atual: correção da calibração de câmera

Achado desta sessão (16/08): a calibração original, com os 4 intrínsecos livres (f_x, f_y, c_x, c_y), estava mal-condicionada: f_x ficou 33% acima do valor geometricamente esperado, apesar de um erro de reprojeção baixo (0,162px).

Causa raiz: com a câmera fixa olhando reto para baixo, o tabuleiro de calibração fica sempre fronto-paralelo ao sensor em todas as poses. Esse é o caso degenerado clássico do método de Zhang (2000) — sem variação de inclinação relativa entre sensor e alvo, f_x e a distância percebida ficam quase linearmente dependentes.

Correção aplicada: como a geometria da câmera simulada já era conhecida com precisão (altura e campo de visão nominais exatos), fixamos f_x, f_y, c_x, c_y no valor geométrico nominal e calibramos apenas a distorção. Esse é o remédio padrão quando os intrínsecos nominais já são confiáveis.

Resultado: a calibração corrigida reproduz a projeção heurística já usada em produção a menos de 0,001m de diferença, o que confirma a equivalência geométrica entre as duas.

Nenhum resultado já publicado no paper muda — a heurística de produção nunca esteve errada, e só uma calibração alternativa em teste é que estava mal-condicionada.

Estado: paper com 10 páginas escritas (limite real do CFP é 12), prazo de submissão **04/09/2026**, formato Springer CCIS, revisão double-blind via Microsoft CMT.

Referências-chave e próximos passos

LARS — bibliografia essencial:

- ▶ Henderson et al. (2018): reprodutibilidade em RL profundo, motiva o teste pareado.
- ▶ Huang & Ontañón (2022): action masking produz gradiente válido; no nosso domínio elimina a violação sem fechar o gap.
- ▶ Agrawal et al. (2023, RTAW), Paul et al. (2022, Capsule Attention): arquiteturas atencionais como direção futura.

Próximos passos: aguardar aceite (15/09/2026); espaço de ação e orçamento de treino maiores; formulação Dec-POMDP (CTDE).

LA Fusion — bibliografia essencial:

- ▶ Sinopoli (2004), Bailey & Durrant-Whyte (2006), Dissanayake et al. (2001): fundamentação teórica clássica do achado central (erro contínuo, modelo EKF, convergência sob observação densa).
- ▶ Khosravi et al. (2026): localização cooperativa com fusão assíncrona, cenário mais próximo do nosso.
- ▶ Ahmed & Frémont (2026): rastreo multi-robô descentralizado, mesma classe de problema.
- ▶ Dobrynin & Garcia (2025): testbed TurtleBot3 com EKF distribuído.

Próximos passos: submissão no CMT até 04/09/2026; Q adaptativo por tempo desde a última correção; Jacobiano completo na projeção; associação robusta (Hungarian/JPDA); LiDAR como terceira fonte.

Conclusão — LARS: um resultado negativo, testado e explicado causalmente. O *action masking* refuta a explicação mais plausível a priori, redirecionando o diagnóstico para o espaço de ação pequeno e o orçamento de treino. **LA Fusion:** um ganho real nos instantes de correção (+23,7%), mas mensuravelmente pior que a odometria pura quando avaliado continuamente (−12,7%). A teoria estabelecida de filtragem sob observação intermitente explica essa reversão como comportamento esperado do filtro, e não como falha de implementação. Os dois trabalhos compartilham o mesmo padrão: reportar o resultado completo, favorável ou não, e fundamentá-lo.